Course 4:
Baisc data management (Part2)

1 Creating new variables
2 Recoding variables
3 Renaming variables
4 Missing values
5 Type conversions
6 Sorting data
7 Merging dataset
8 Subsetting datasets
9 Summary

Sorting data

order() function

- order() 可以根据一个或多个列的值来对数据框（data frame）进行排序

例 1：对向量进行排序

```
# 创建一个数值向量
numbers <- c(4, 1, 7, 3, 8, 2)
# 使用order()获取排序的索引
order(numbers)
#以上会输出由小到大的元素对应的位置，即2, 6, 4, 1, 3, 5
# 对向量进行排序
numbers[order(numbers)]
#以上会输出1 2 3 4 7 8
```

Sorting data

例 2：对数据框的单列进行排序

假设我们有一个数据框，我们想要根据其中一列的值来排序整个数据框

```r
# 创建一个数据框
df <- data.frame(name = c("Alice", "Bob", "Cindy", "Dan"),
                 age = c(25, 22, 30, 24))
# 使用order()根据年龄排序
df[order(df$age), ]
```

Sorting data

例 3：根据多列进行排序

可以使用 order() 函数根据多个列来进行排序，如果第一列的值相同，则根据第二列的值进行排序。

```r
# 创建一个数据框
df <- data.frame(department = c("HR", "IT", "HR", "IT"),
                 salary = c(5000, 4500, 5500, 4000))
# 使用order()根据部门和薪水进行排序
df[order(df$department, df$salary), ]
#order(df$department, df$salary)返回1, 3, 4, 2
```

注：在以上三个例子中，order() 函数返回的是排序后元素的索引，我们使用这些索引来对原始向量或数据框进行排序。

1 Creating new variables
2 Recoding variables
3 Renaming variables
4 Missing values
5 Type conversions
6 Sorting data
7 Merging dataset
8 Subsetting datasets
9 Summary

Merging datasets: 列合并

简单并列排放：cbind()

- cbind() 用于按列将向量、矩阵或数据框组合成一个新的数据框或矩阵。它简单地将数据结构侧向拼接起来，不考虑行之间的任何匹配或关系。
- cbind() 并不关心行的对应关系，只是将数据结构侧向（列方向）合并。因此，所有输入的数据结构必须有相同数量的行。

```
1        cbind(dataframe1, dataframe2)
```

Merging datasets: 列合并

匹配合并：merge()

使用 merge() 函数通过一个或多个公共键（key）变量水平合并（即内连接）两个数据框，即添加更多的变量。

```
#根据ID把A和B合并
total <- merge(dataframeA, dataframeB, by = "ID")
#根据ID和country把A和B合并
total <- merge(dataframeA, dataframeB, by = c("ID","Country"))
```

Merging datasets: 行合并

垂直连接/添加观察值: rbind()

rbind 代表 “row bind”，即 “按行绑定”：

- 两个数据框必须有相同的变量，但它们不必顺序相同
- 如果 dataframeA 含有 dataframeB 所没有的变量，那么在合并它们之前，做以下其中一项操作：
  - 删除 dataframeA 中的额外变量
  - 在 dataframeB 中创建额外的变量，并将它们设置为 NA（缺失值）

1 Creating new variables
2 Recoding variables
3 Renaming variables
4 Missing values
5 Type conversions
6 Sorting data
7 Merging dataset
8 Subsetting datasets
9 Summary

Subsetting datasets

Selecting(keeping) variables: [ ]

从一个较大的数据集中选择有限数量的变量来创建一个新的数据集:

```
#在数据Data中选择第1到5列，并存为新数据newdata
newdata <- Data[, c(1:5)]
#省略行索引（仅保留逗号）会默认选择所有行
#也可以调用变量名字，比如：
newdata <- Data[, c("Var1", "Var3")]
```

Subsetting datasets

Excluding(dropping) variables: 负号 -

可以使用负号-来排除某些列：

```
#排除第三和第五列
newdata <- Data[, -c(3, 5)]
```

Subsetting datasets

Selecting observations

```
#选取一个数据集的前三行样本:
newdata <- Data[1:3, ]
#选取数据集中年龄大于30的男性:
newdata <- Data[Data$age > 30 & Data$gender == "M", ]
```

Subsetting datasets

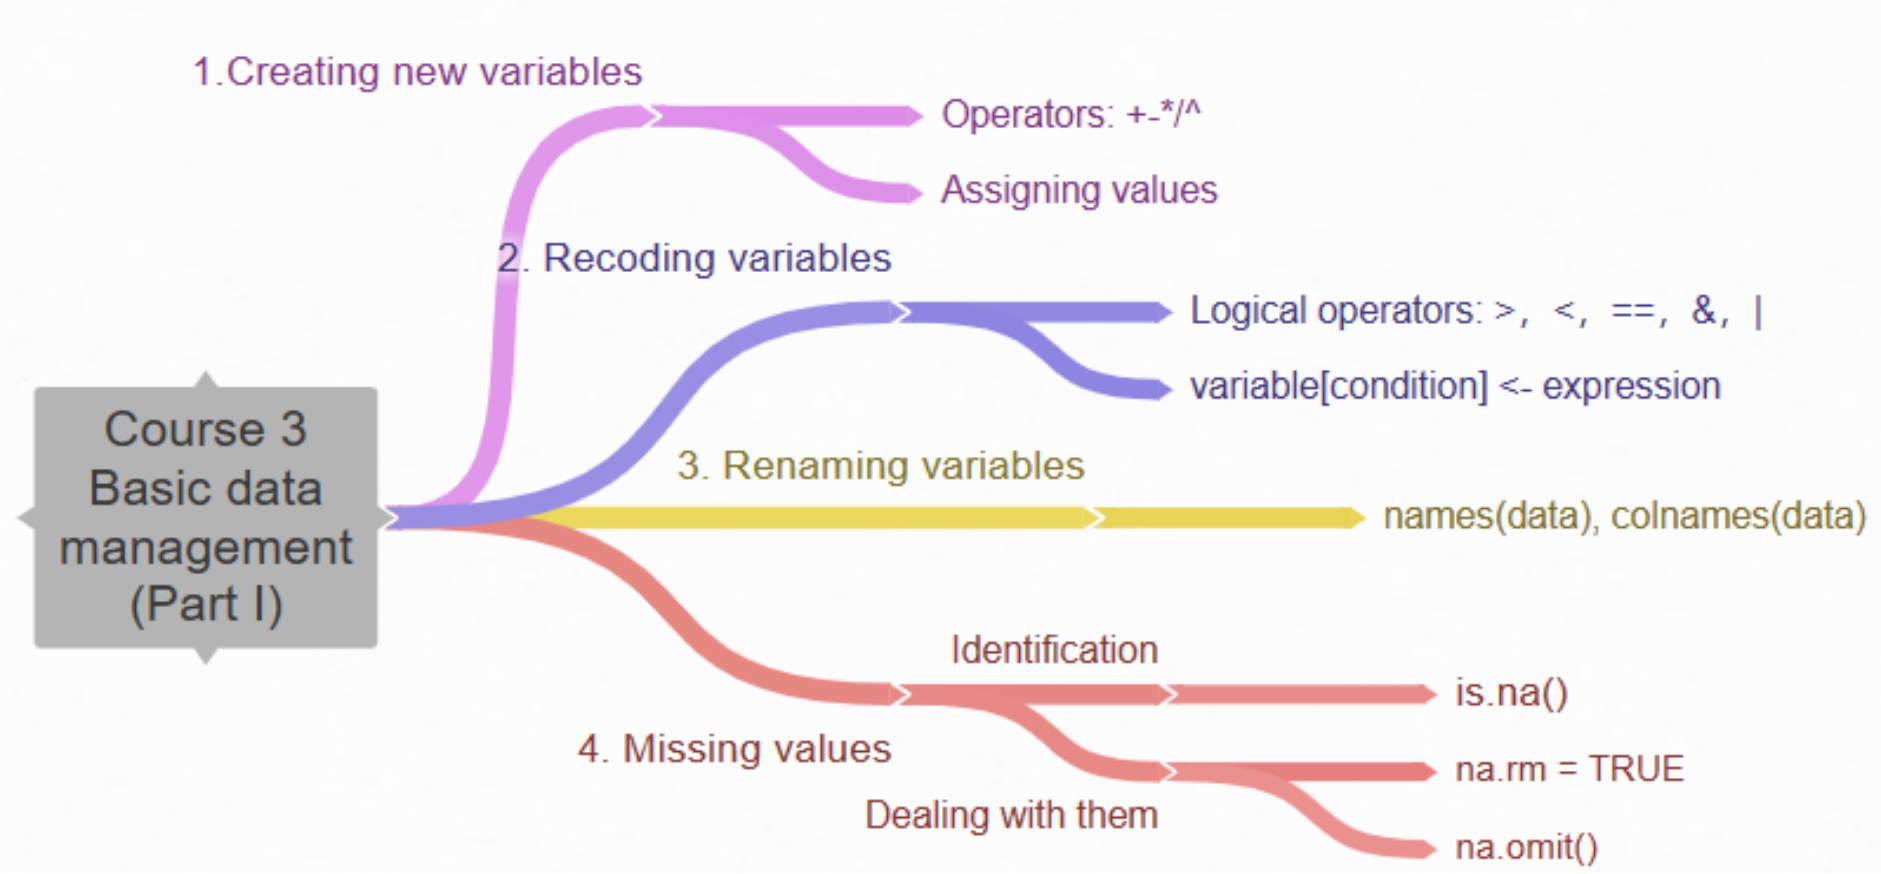
subset()

subset 函数：

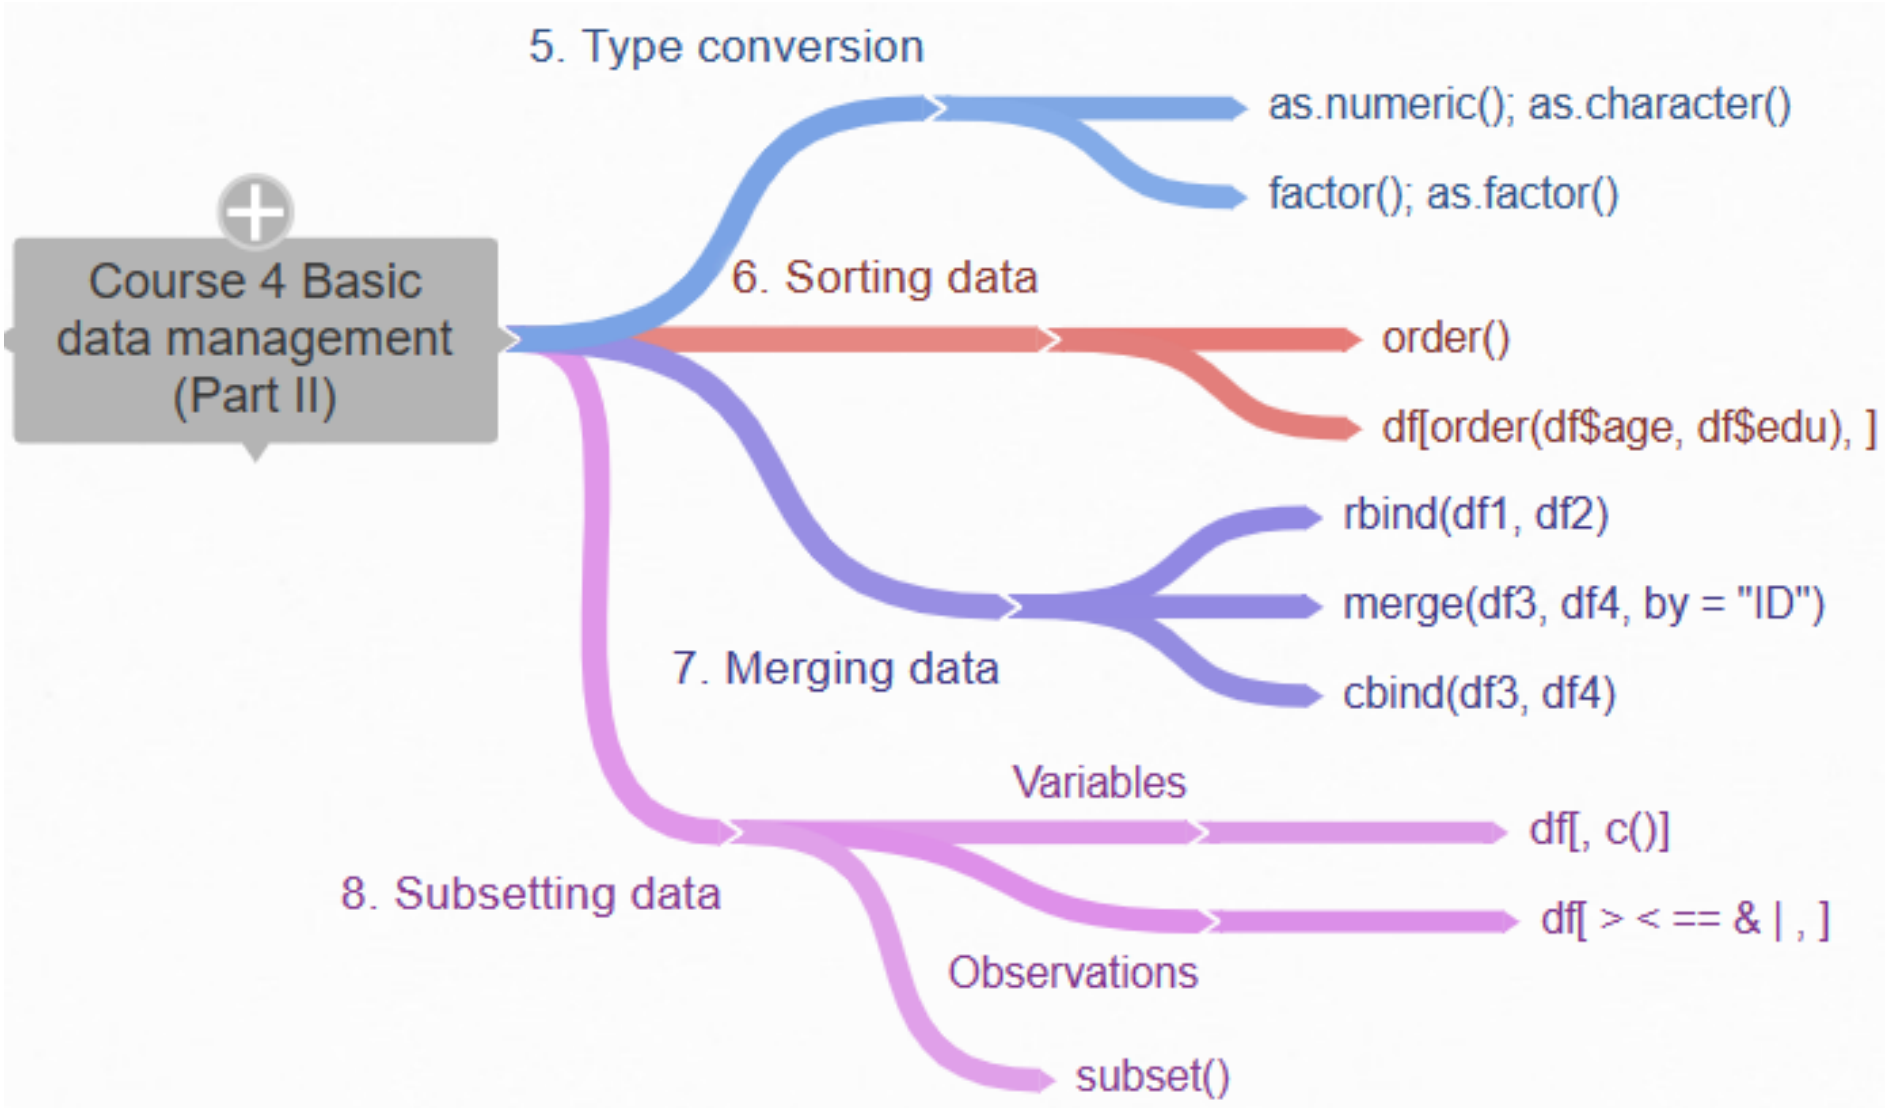
```
1       #选取样本：
2     newdata <- subset(Data, age > 30 & gender == "M")
3     #选取变量：
4     newdta <- subset(Data, select = c(q1, q2))
5     #选取样本和变量：
6     newdata <- subset(Data, age > 30 & gender == "M",  select = c(
          q1, q2))
```

1 Creating new variables
2 Recoding variables
3 Renaming variables
4 Missing values
5 Type conversions
6 Sorting data
7 Merging dataset
8 Subsetting datasets
9 Summary

Summary Part I



Summary Part II



Exercise

先创建一个示例数据框 df (已在 R script 中)，并进行以下操作:

1. 创建新变量. 在 df 中创建一个新变量 AgeGroup，其规则如下：小于 25 岁"Young"; 25-30 "Adult"; 大于 30 "Senior"
2. 变量重编码. Gender： "M" 替换为"Male"; "F" 替换为"Female"
3. 变量重命名. 将"Score" 改为"Exam_Score"
4. 处理缺失值.
   - 计算 df 中有多少个 NA 值
   - 用变量的均值填充 Age 和 Score 中的缺失值

Exercise

5. 数据类型转换
   - 将 ID 变量转换为 factor 类型
   - 将 Exam_Score 转换为 character 类型
6. 排序数据. 按照 Age 从小到大排序。如有缺失值，则放在最后
7. 合并数据. 将 df 与 df2 按 ID 合并, 并保留所有样本
8. 选取子集
   - 选取 Age 大于 25 岁且 Gender 为"Female" 的行
   - 仅保留 ID、Name 和 Exam_Score 变量