Course 5
概率和概率分布

Jiayun Jin

1 随机事件及其概率

2 离散型随机变量及其分布
- 随机变量的概念
- 离散概率分布

3 连续概率分布
- 概率密度与分布函数
- 正态分布
- 正态分布在质量管理中的应用

随机事件

考虑随意抛掷色子：

- 随机事件：出现 1 点、2 点……6 点 $\rightarrow$ 可能出现也可能不出现的事件；**不确定性**是随机事件的关键特征
- 必然事件/确定性事件：点数小于 7 $\rightarrow$ 每次试验一定出现的事件
- 不可能事件：点数大于 6 $\rightarrow$ 每次试验一定不出现的事件

如何描述随机事件发生的可能性？

随机事件的概率

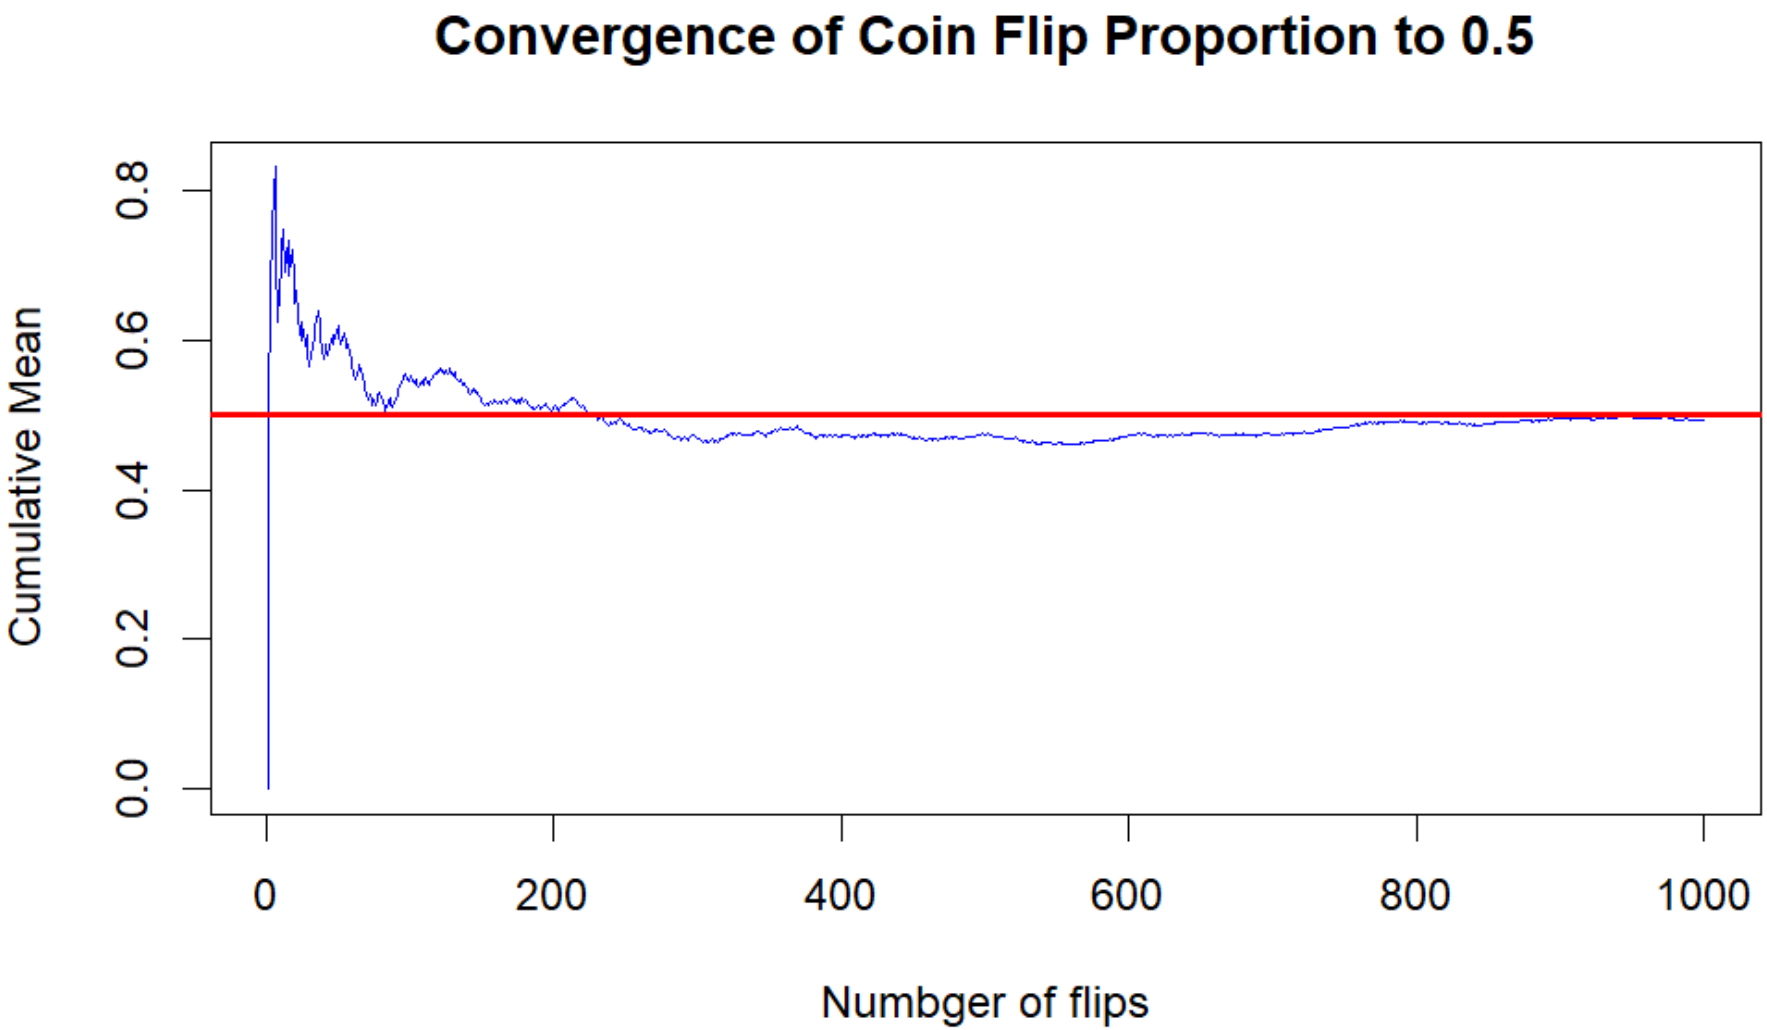
概率的统计定义

在相同条件下试验 n 次，某事件 A 出现 m 次 $(m \leq n)$，则比值 $\frac{m}{n}$ 称为事件 A 发生的频率。

随着 n 的增大，该频率围绕某一常数 p 上下波动，且波动的幅度逐渐减小趋于稳定。这个频率的稳定值即为该事件的概率，记为：

$$P(A) = \frac{m}{n} = p$$

随机事件的概率


Convergence of Coin Flip Proportion to 0.5
Cumulative Mean
0.0
0.2
0.4
0.6
0.8
0
200
400
600
800
1000
Numbger of flips

1 随机事件及其概率

2 离散型随机变量及其分布
- 随机变量的概念
- 离散概率分布

3 连续概率分布
- 概率密度与分布函数
- 正态分布
- 正态分布在质量管理中的应用

离散型随机变量及其分布

随机变量

- 用 X 代表随机事件 A，x_i 代表随机事件的可能情况：

$$P(x_i) = P(X = x_i)\text{称为随机变量 X 的概率函数}$$

- 比如抛掷一枚硬币，正面情况可设为 $X = x_1$，反面情况 $X = x_2$

$$P(X = x_1) = \frac{1}{2}$$
$$P(X = x_2) = \frac{1}{2}$$

离散型随机变量的概率分布

- 设有离散型随机变量 X，可能取值 $x_1, x_2, ..., x_n$，其对应的概率为 $p_1, p_2, ..., p_n$，即 $P(X = x_i) = p_i (i = 1, 2, ..., n)$:

X=x_i	x_1	x_2	...	x_n
P(X=x_i)=p_i	p_1	p_2	...	p_n

- 该表格为离散型随机变量 X 的概率分布，其中 $P(X = x_i) = p_i$ 是 X 的概率函数。因为 $x_1, x_2, ..., x_n$ 构成一个完备组，所以有:

$$\sum_{i=1}^{n} p_i = 1$$

离散概率分布

- 抛掷色子，出现的点数是一个离散型随机变量 X，其概率分布函数如下：

X	1	2	3	4	5	6
P(X)	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

$$\sum_{i=1}^{6} p_i = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = 1$$

离散型随机变量的期望值和方差

期望值

若 X 取数值 $x_1, x_2, \ldots, x_n$，其对应的概率为 $p_1, p_2, \ldots, p_n$，则期望值为：

$$\mu = E(x) = x_1 p_1 + x_2 p_2 + \ldots + x_n p_n = \sum_{i=1}^{n} x_i p_i$$

期望值是随机变量取值的加权平均，反映了随机变量取值的中心位置

以掷色子为例，它的期望值为：

$$\begin{aligned}\mu = E(x) &= \sum_{i=1}^{6} x_i p_i \\ &= 1 \times \frac{1}{6} + 2 \times \frac{1}{6} + 3 \times \frac{1}{6} + 4 \times \frac{1}{6} + 5 \times \frac{1}{6} + 6 \times \frac{1}{6} = 3.5\end{aligned}$$

离散型随机变量的期望和方差

方差与标准差

方差衡量随机变量取值的离散程度，即变量取值与期望值之间差异的平方的期望值。设随机变量为 X，其方差常用 σ_x^2 表示：

$$\sigma^2 = D(X) = E[X - E(X)]^2 = \sum_{i=1}^{\infty} p_i[x_i - E(X)]^2$$

以掷色子为例，它的方差为：

$$\begin{aligned}
\sigma^2 &= \sum_{i=1}^{6} p_i(x_i - E(X))^2 \\
&= (1-3.5)^2 \times \frac{1}{6} + (2-3.5)^2 \times \frac{1}{6} + (3-3.5)^2 \times \frac{1}{6} \\
&+ (4-3.5)^2 \times \frac{1}{6} + (5-3.5)^2 \times \frac{1}{6} + (6-3.5) \times \frac{1}{6} \\
&= 2.9167
\end{aligned}$$

练习

制造业中，从生产线上随机检查的一批产品中缺陷产品的数量 X：

缺陷产品 x(%)	概率 p(x)
5	0.2
6	0.15
7	0.4
8	0.15
9	0.1

练习

制造业中，从生产线上随机检查的一批产品中缺陷产品的数量 X:

缺陷产品 x(%)	概率 p(x)
5	0.2
6	0.15
7	0.4
8	0.15
9	0.1

$$\mu = 5 \times 0.2 + 6 \times 0.15... = 6.8$$

$$\sigma^2 = (5 - 6.8)^2 \times 0.05 + ... + (9 - 6.8)^2 \times 0.1 = 1.46$$

离散概率分布

1. 二项分布 Binomial
   - 二项实验 Bernoulli trial
2. 泊松分布 Poisson

离散概率分布

Bernoulli trial: $B(1, p)$

- 只有两个可能的结果，通常称为 “成功” 和 “失败”
- 每次实验的成功概率是相同的
- 每次实验是独立的

例如，抛一枚硬币就是一个典型的二项实验，结果只可能是正面或反面。

离散概率分布

Binomial 二项分布: $B(n, p)$

- 二项分布是一系列 Bernoulli 实验结果的概率分布;
- 描述了在固定次数的二项实验中获得特定数量成功的概率

- **n**: 实验的总次数
- **p**: 每次实验成功的概率

离散型变量概率分布

Binomial

- If $X \sim B(n, p)$:

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, k = 0, 1, 2, ..., n$$

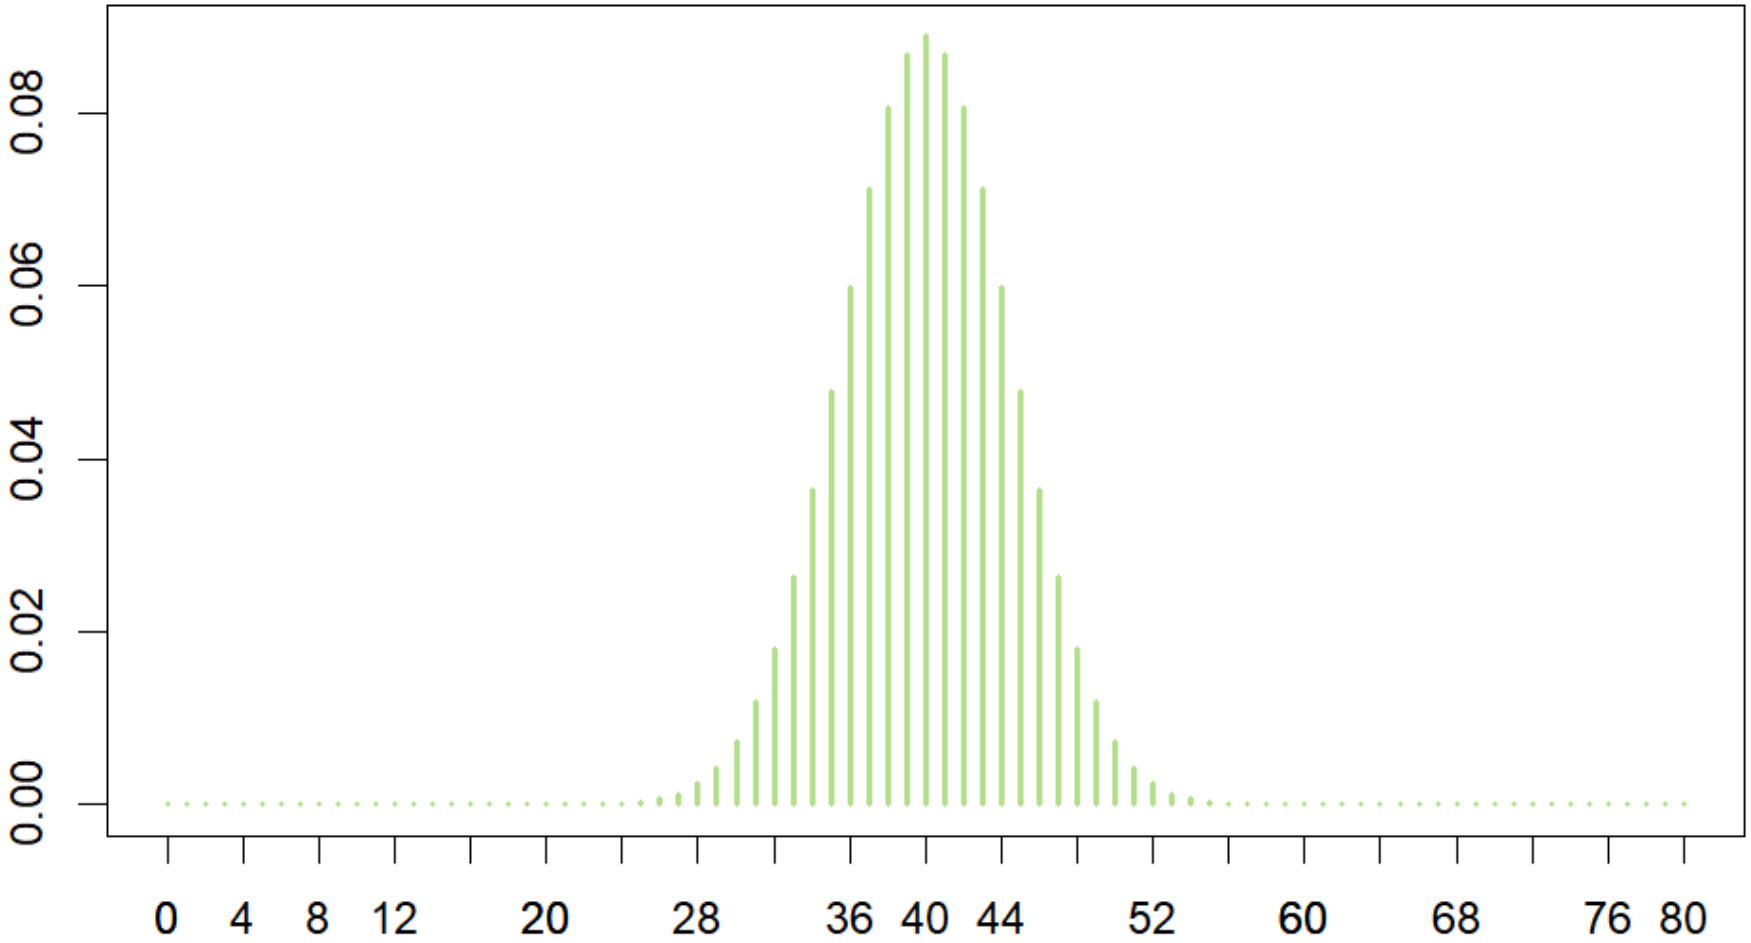
$P(X = k)$ 是在 n 次实验中恰好有 k 次成功的概率

Mean and variance

$$E(X) = np$$
$$D(X) = np(1-p)$$

Binomial

$X \sim B(80, 0.5)$



Binomial

Examples

- number of side effects from medications (100 patients, 0.05)
- number of fraudulent transactions (50 transactions, 0.02)
- number of spam emails per day (20 emails per day, 0.04)
- shopping returns per week (50 orders per week, 0.1)

Binomial

Summary

- 理解二项分布，就是理解在一系列独立且相同的实验中，某事件发生特定次数的概率分布
- 二项分布的核心在于把握实验次数 n、成功概率 p、以及成功次数之间的关系 k

离散概率分布

泊松分布 Poisson

- 用于描述在固定时间间隔或空间区域内发生某些事件的次数的概率分布。这些事件是随机的，彼此独立，且发生的平均率（或强度）是已知的。
  - Events: could be anything from disease cases to customer purchases to earthquakes
  - Interval: can be any specific amount of time or space, such as 10 days or 5 square meters

Poisson

Examples

- 通信：在一定时间内接到的电话呼叫数量
- 交通工程：在特定时间段内通过特定点的车辆数
- 零售业：一个小时内到达的客户数量
- 自然科学：一平方米内发现的罕见植物的数量；一天内发生的地震数量。

离散概率分布

Poisson(λ)

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, ...$$

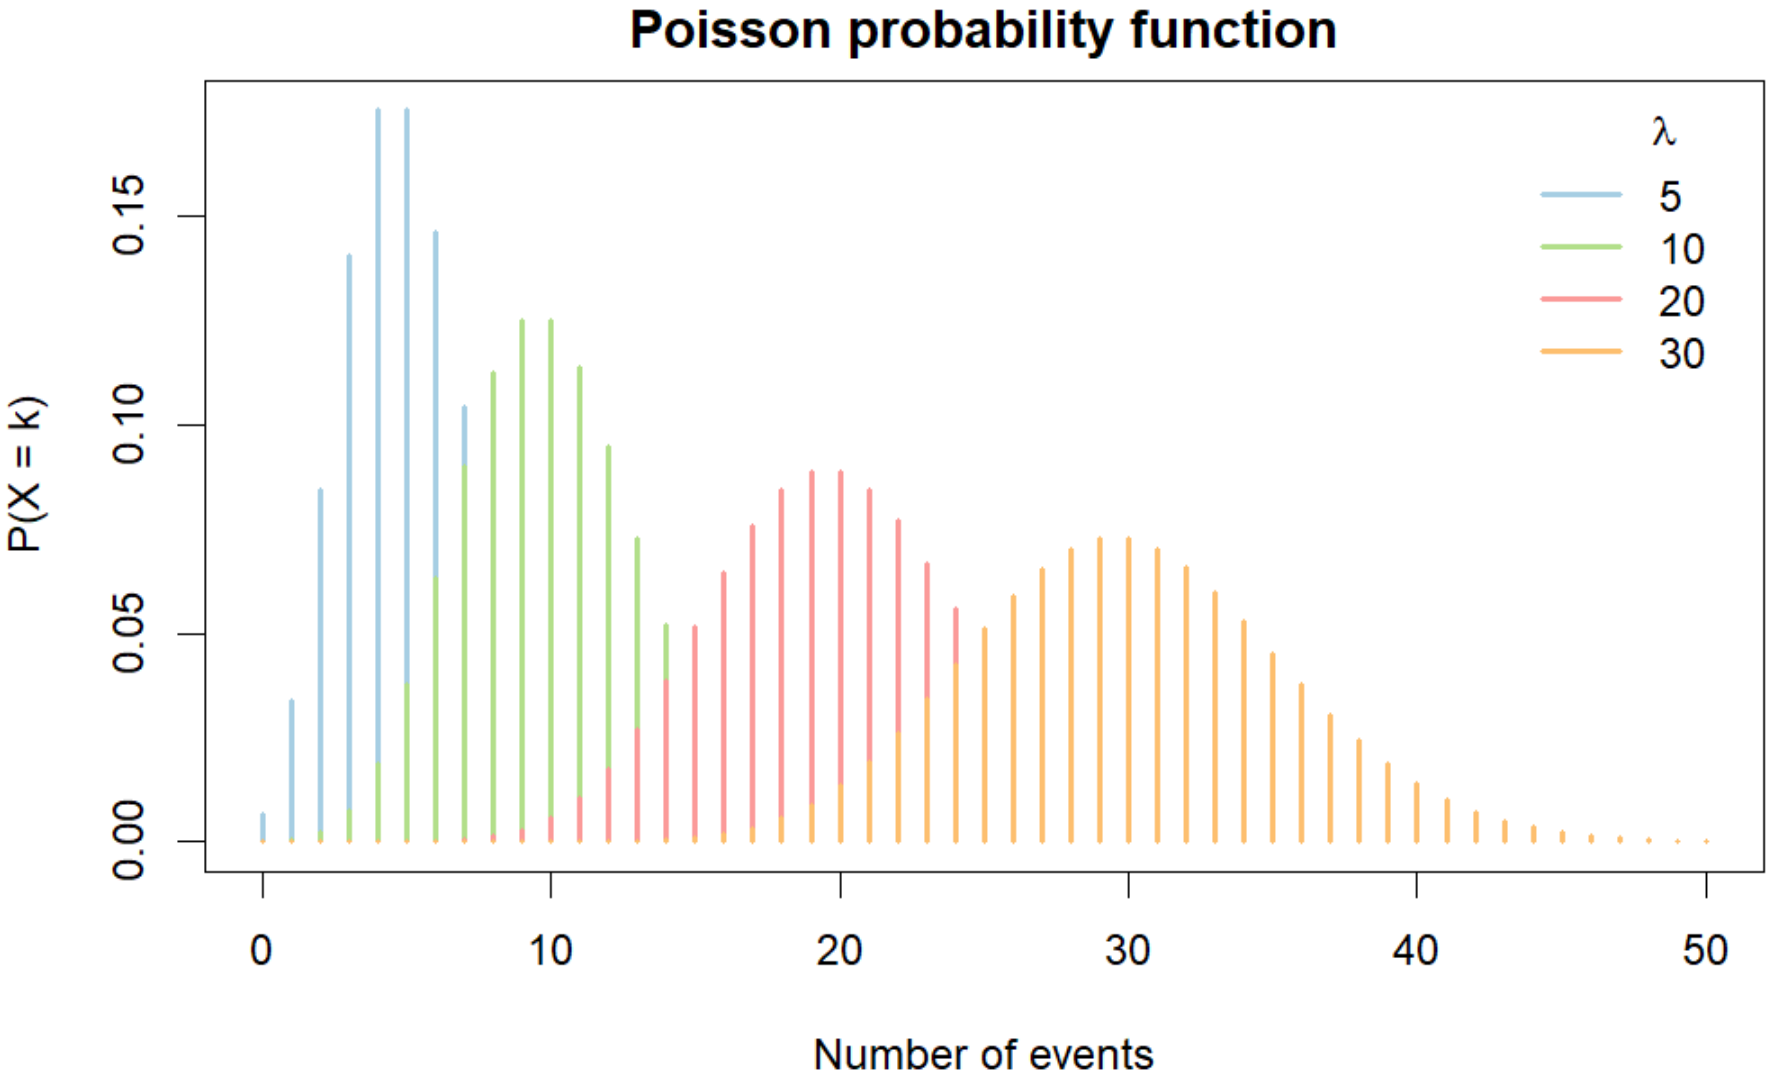
- X is a random variable following a Poisson distribution
- k is the number of times an event occurs
- P($X = k$)is the probability that an event occurs k times
- λ is the average number of times an event occurs

离散概率分布

Mean and variance

$$E(X) = \lambda$$
$$D(X) = \lambda$$

- 期望和方差相等，都等于 λ
- 如果事件的平均发生率增加，其发生次数的变异性也会增加


Poisson probability function
P(X = k)
0.00
0.05
0.10
0.15
0
10
20
30
40
50
Number of events
λ
5
10
20
30

Poisson

Exercise

一个小镇的警察局平均每月发出 5 张超速罚单。使用泊松随机变量，警察局在一个月内发出 3 张或更少罚单的可能性是多少？

$$P(Y \leq 3) = P(Y = 0) + P(Y = 1) + P(Y = 2) + P(Y = 3)$$

$$P(Y \leq 3) = \frac{5^0 e^{-5}}{0!} + \frac{5^1 e^{-5}}{1!} + \frac{5^2 e^{-5}}{2!} + \frac{5^3 e^{-5}}{3!}$$

$$= 0.27$$

1. 随机事件及其概率

2. 离散型随机变量及其分布
   - 随机变量的概念
   - 离散概率分布

3. 连续概率分布
   - 概率密度与分布函数
   - 正态分布
   - 正态分布在质量管理中的应用

连续型随机变量 Continuous variables

Discrete vs Continuous

- 连续型随机变量可以在某个区间内取任意值，例如，一个人的身高、一段时间内降雨的量或者汽车的行驶速度。
- 离散型随机变量的取值是有限的或者是可数无限的，例如，掷骰子的结果或者一天内接到的电话数量。
- 对于连续随机变量来说，任何一个具体值的概率都是 0，而我们关心的是变量落在某个区间内的概率

Continuous probability distributions

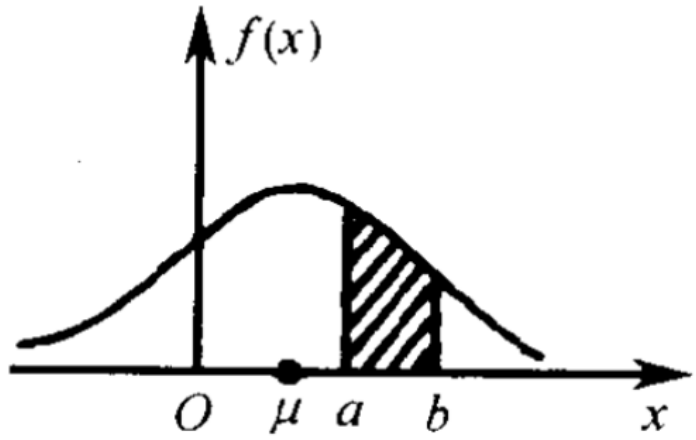
概率密度函数 probability density function/pdf: f(x)

- A probability density function can be represented as an equation or as a graph:

$$f(x) \geq 0$$

$$\int_{-\infty}^{\infty} f(x)dx = 1$$

$$P(a < X < b) = \int_{a}^{b} f(x)dx$$



连续概率分布

概率密度函数 Probability density function: f(x)

- The probability that a value will fall within a certain interval is determined by calculating the area under the curve within that interval.
- The area under the whole curve is always exactly one.

Continuous probability distributions

累积分布函数 Cumulative distribution functions/cdf: F(x)

CDF 表示随机变量取值小于或等于某个值的概率;
CDF 是 PDF 的积分，可以直接给出随机变量落在负无穷到 x 区间内的概率。

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt, -\infty < x < \infty$$

$$f(x) = F^{'}(x)$$

$$\begin{aligned} P(a < X < b) &= \int_{a}^{b} f(x)dx \\ &= F(b) - F(a) \end{aligned}$$

$$P(X = a) = 0$$

Continuous probability distributions

Mean and variance

$$E(x) = \int_{-\infty}^{\infty} xf(x)dx = \mu$$

$$D(x) = \int_{-\infty}^{\infty} [x - E(x)]^2 f(x)dx = \sigma^2$$

Normal Distribution

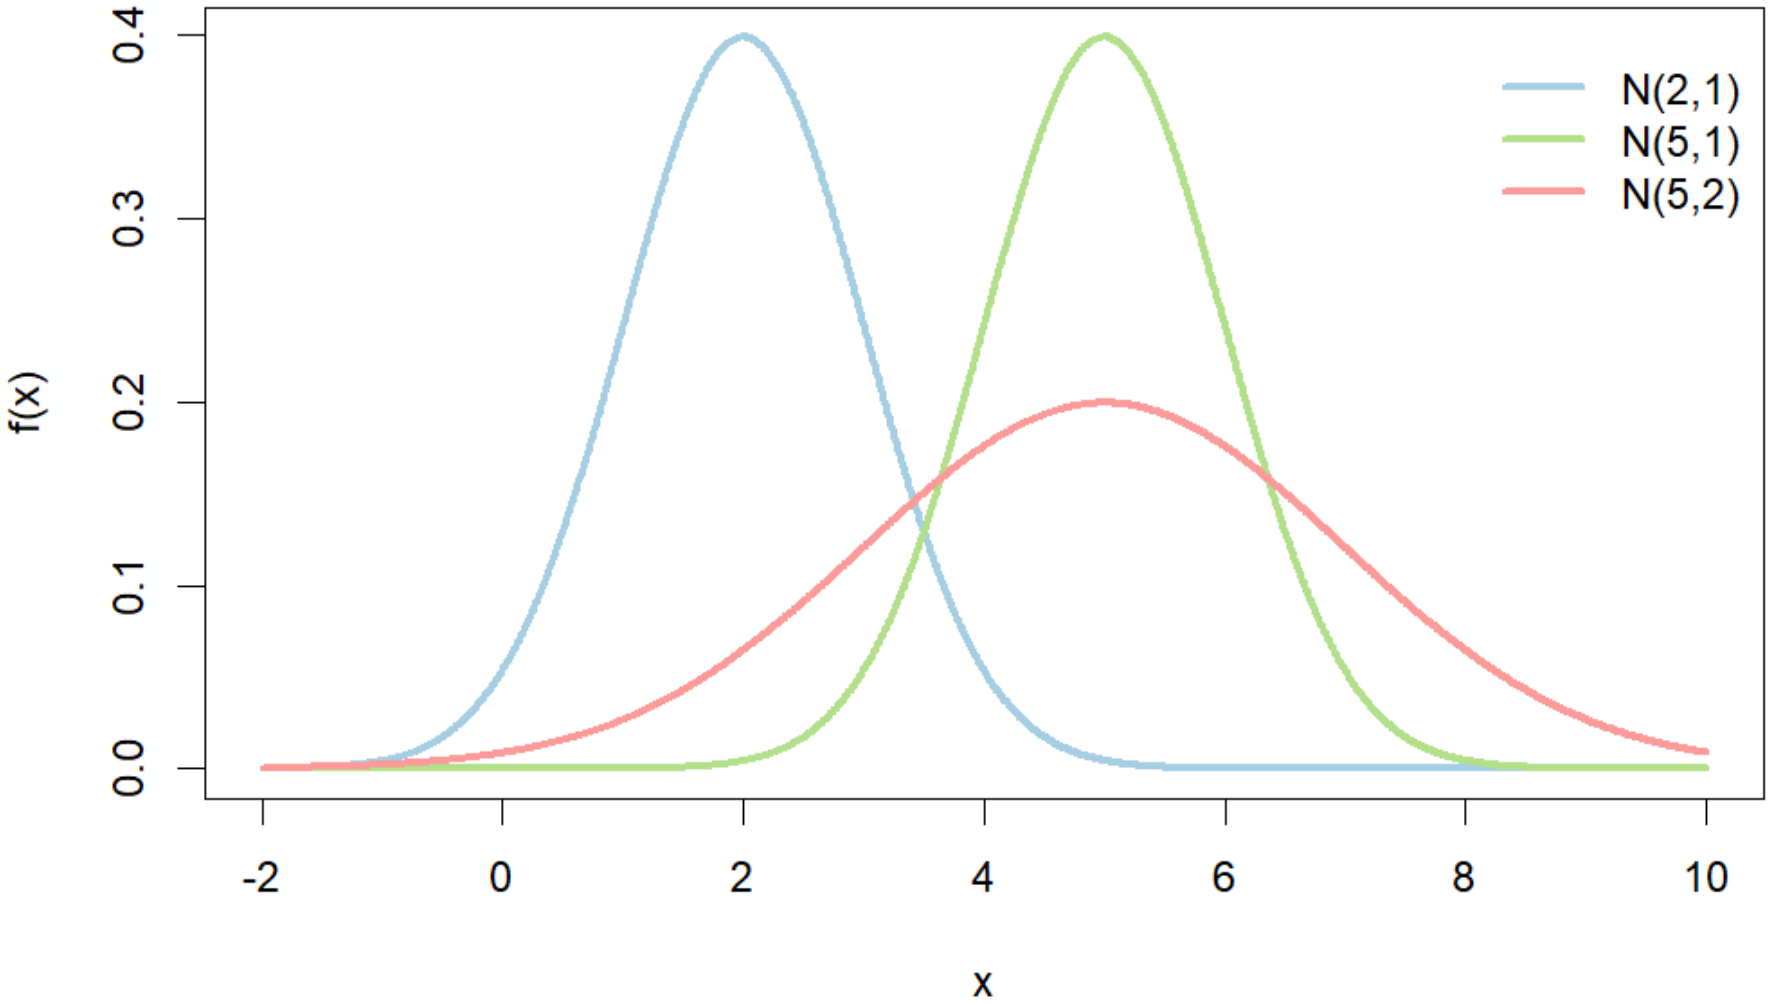
Probability density function

$X \sim \mathcal{N}(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, -\infty < x < +\infty$$

μ is the mean and σ is the standard deviation。

正态分布 Normal distribution



Normal distribution

Properties

1. The mean, median and mode are exactly the same.
2. The distribution is symmetric about the mean
3. The distribution can be described by two values: the mean (location) and the standard deviation (scale).

Why does it matter?

- Too common
- Height, birth weight of babies, shoe sizes, blood pressure...

Standard normal distribution

$\mathcal{N}(0,1) : \mu = 0, \sigma = 1$

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, -\infty < x < +\infty$$

$$\Phi(x) = \int_{-\infty}^{x} \varphi(t)dt = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

Standard normal distribution

$\mathcal{N}(0,1) : \mu = 0, \sigma = 1$

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, -\infty < x < +\infty$$

$$\Phi(x) = \int_{-\infty}^{x} \varphi(t)dt = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$



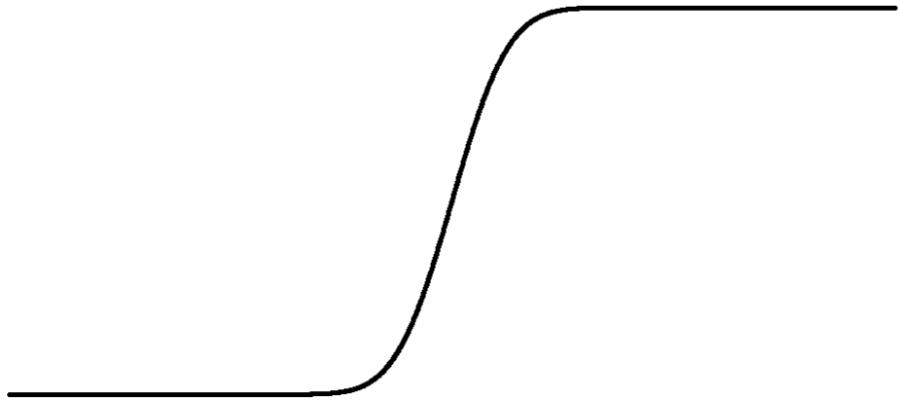
Standard normal distribution

$\mathcal{N}(0,1) : \mu = 0, \sigma = 1$

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, -\infty < x < +\infty$$

$$\Phi(x) = \int_{-\infty}^{x} \varphi(t)dt = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$



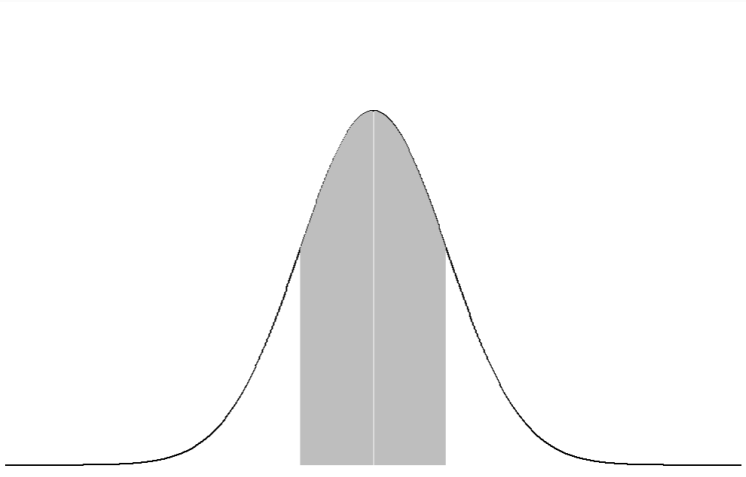


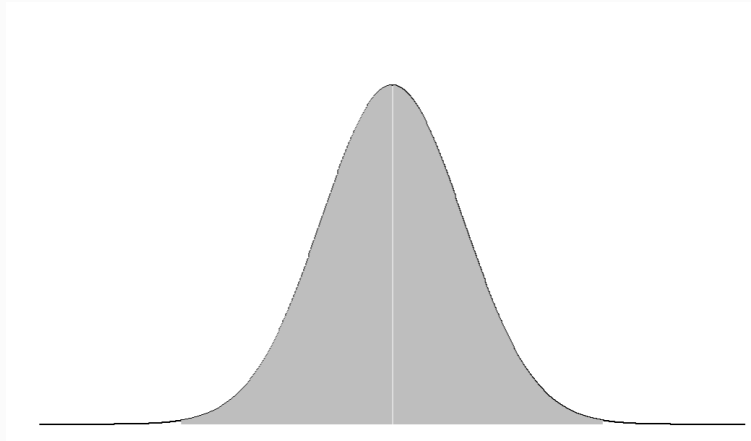
Normal distributions in quality control

3σ principle ($X \sim \mathcal{N}(\mu, \sigma^2)$)

$$
\begin{aligned}
&P(\mu - \sigma < X < \mu + \sigma) \\
&= P(-1 < \frac{X - \mu}{\sigma} < 1) \\
&= P(-1 < Z < 1) \\
&= \Phi(1) - \Phi(-1) = 0.6827
\end{aligned}
$$

$$
\begin{aligned}
&P(\mu - 3\sigma < X < \mu + 3\sigma) \\
&= P(-3 < \frac{X - \mu}{\sigma} < 3) \\
&= P(-3 < Z < 3) \\
&= \Phi(3) - \Phi(-3) = 0.9973
\end{aligned}
$$





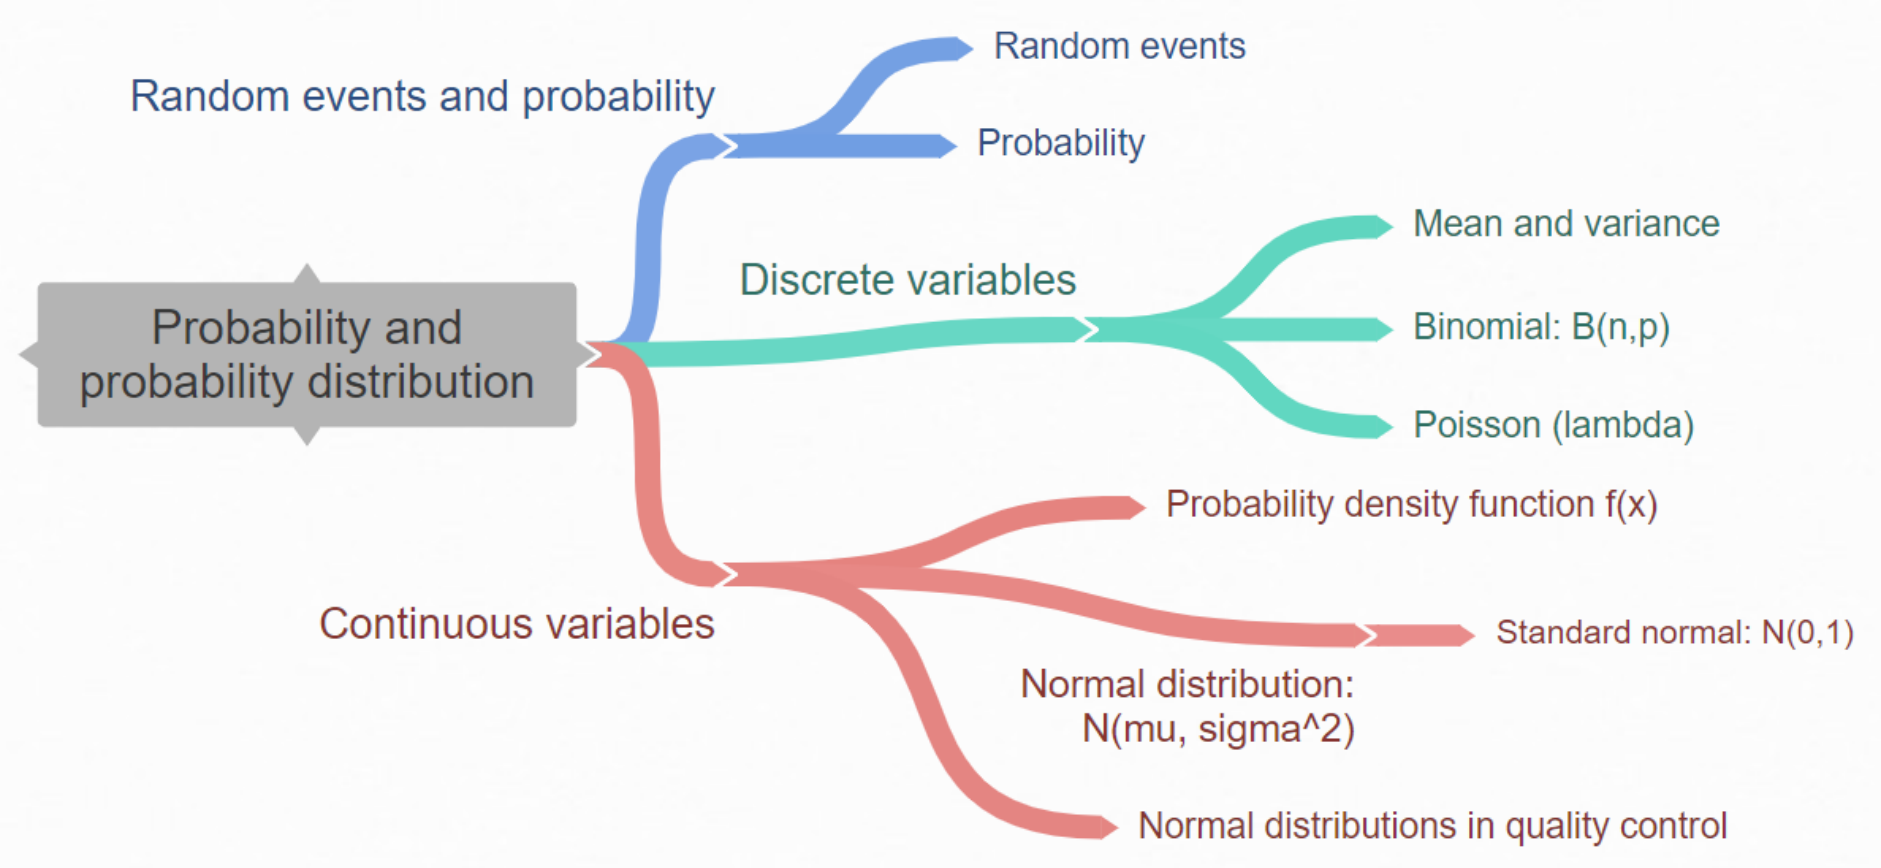
Normal distributions in quality control

3σ principle ($X \sim \mathcal{N}(\mu, \sigma^2)$)

The empirical rule:

1. Around 68% of values are within 1 standard deviation from the mean.
2. Around 95% of values are within 2 standard deviation from the mean.
3. Around 99.7% of values are within 3 standard deviation from the mean.

Summary


Probability and probability distribution
Random events and probability
Random events
Probability
Discrete variables
Mean and variance
Binomial: B(n,p)
Poisson (lambda)
Continuous variables
Probability density function f(x)
Standard normal: N(0,1)
Normal distribution: N(mu, sigma^2)
Normal distributions in quality control