Basic Graphs

Jiayun Jin

1 Review

2 Basic graphs for categorical data

3 Basic graphs for numerical data

Review

1. Introduction to R
2. Creating a dataset in R
3. Basic data management in R (Part I)
4. Basic data management in R (Part II)

5. Probability and distribution
6. Parameter estimation
7. Hypothesis testing

This course

Basic graphs

- Categorical variables
  - e.g., gender
- Numerical variables
  - e.g., height

1 Review

2 Basic graphs for categorical data

3 Basic graphs for numerical data

For categorical data

Categorical variable

Arthritis 数据集（vcd 包）包含对一组类风湿关节炎患者进行的治疗效果研究的数据，主要记录实验性药物治疗和安慰剂的效果。

	ID	Treatment	Sex	Age	Improved
84	1	Placebo	Female	74	Marked
29	2	Treated	Female	59	Marked
78	3	Placebo	Female	64	None
68	4	Placebo	Female	54	None

- Treatment：治疗类型，包括实验药物和安慰剂
- Improved：治疗效果，分为 “None”（无改善）、“Some”（有所改善）和 “Marked”（显著改善）
- Sex：性别
- Age：年龄

For categorical data

Frequency and contingency table

```
#对单个变量做频数表
table(variable)
prop.table(table(variable))
#对两个变量做列联表
table(var1, var2)
prop.table(table(var1, var2))
prop.table(table(var1, var2, 1))
prop.table(table(var1, var2, 2))
```

For categorical data

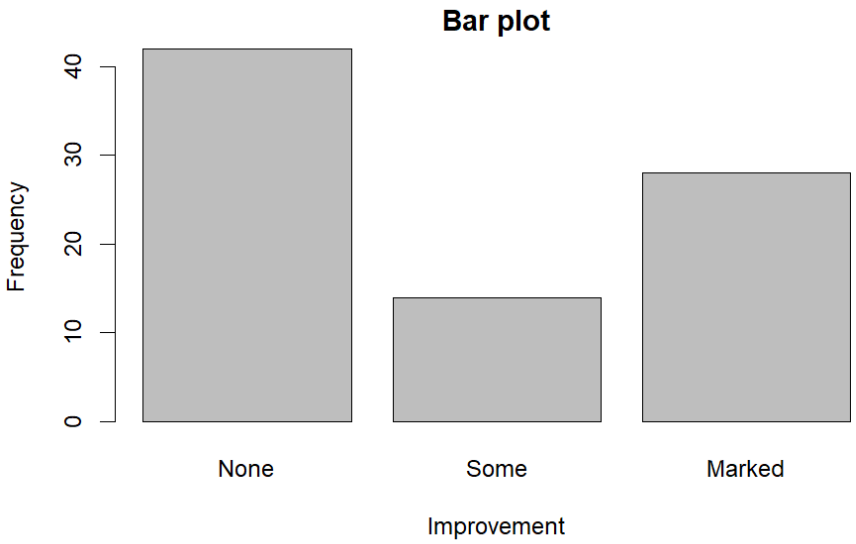
Bar plots 柱状图（条形图）

条形图（Bar Plot）：用于展示分类数据，通过条形的高度或长度来表达数据的大小，非常适合比较不同类别之间的数量差异

```r
barplot(height, names.arg = NULL, main = NULL, xlab = NULL,
    ylab = NULL, col = NULL)
```

- height: 包含要绘制的条形高度的数值向量或矩阵
- names.arg: 可选，条形下方的标签
- main: 可选，图表的主标题
- xlab 和 ylab: 可选，分别为 x 轴和 y 轴的标签
- col: 可选，用于指定条形的颜色

Barplots 条形图

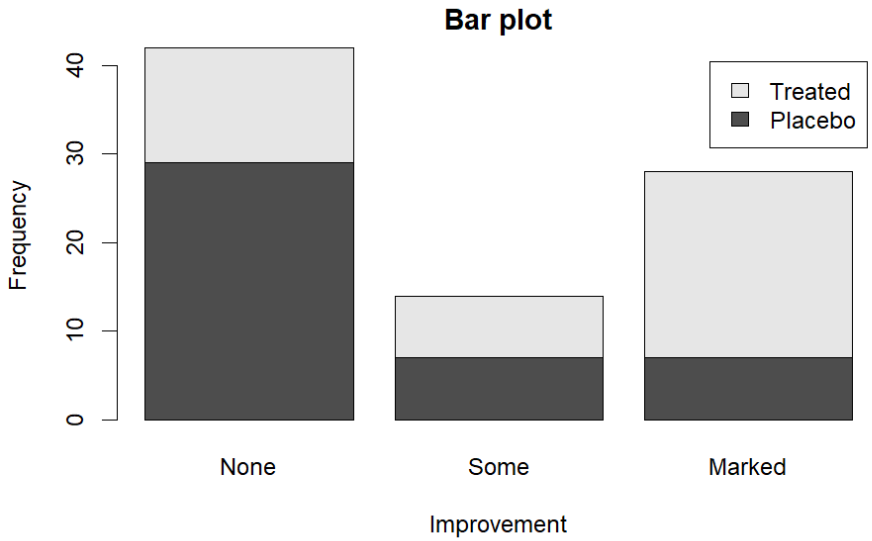


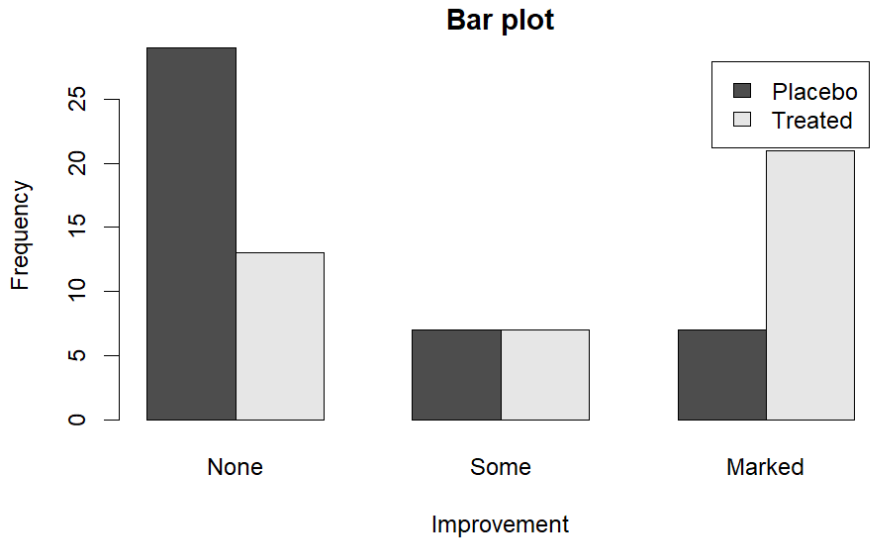


Barplots 条形图









Barplots

两个分类变量

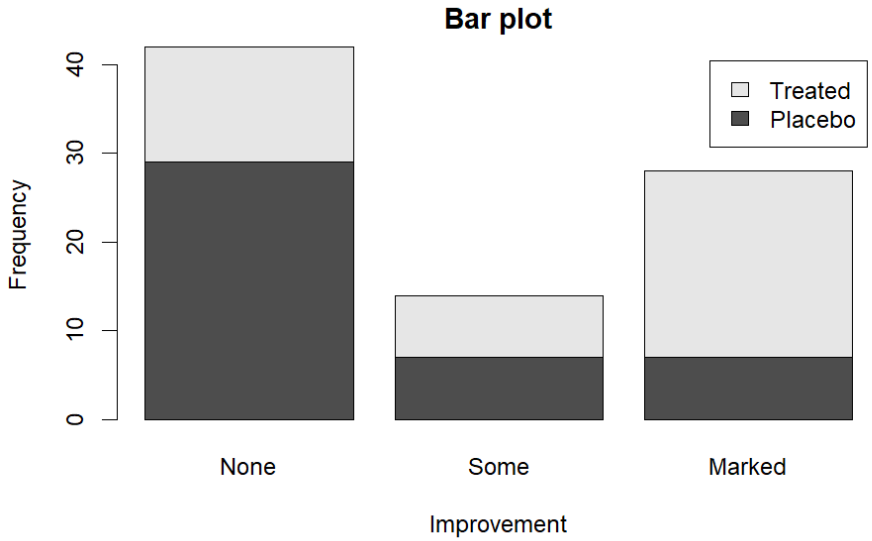
首先计算这两个变量的交叉频数（列联表），然后使用得到的列联表来绘制条形图

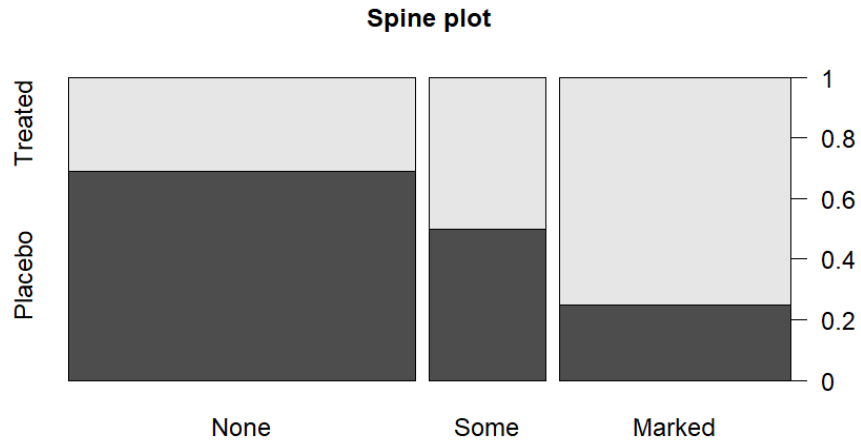
```r
tab <- table(var1, var2)
barplot(tab, beside = TRUE, legend = TRUE, col = c("blue", "red
    "), main = "var1 vs var2", xlab = "var1", ylab = "Frequency
    ")
```

- beside = TRUE 表示将条形图并排显示，以便于比较
- legend = TRUE 添加图例，帮助区分不同的条形
- col = c("blue", "red") 定义了两组数据的颜色
- xlab 和 ylab: 可选，分别为 x 轴和 y 轴的标签
- main, xlab, ylab 分别设置了图表的标题和轴标签

Spine plot 脊线图

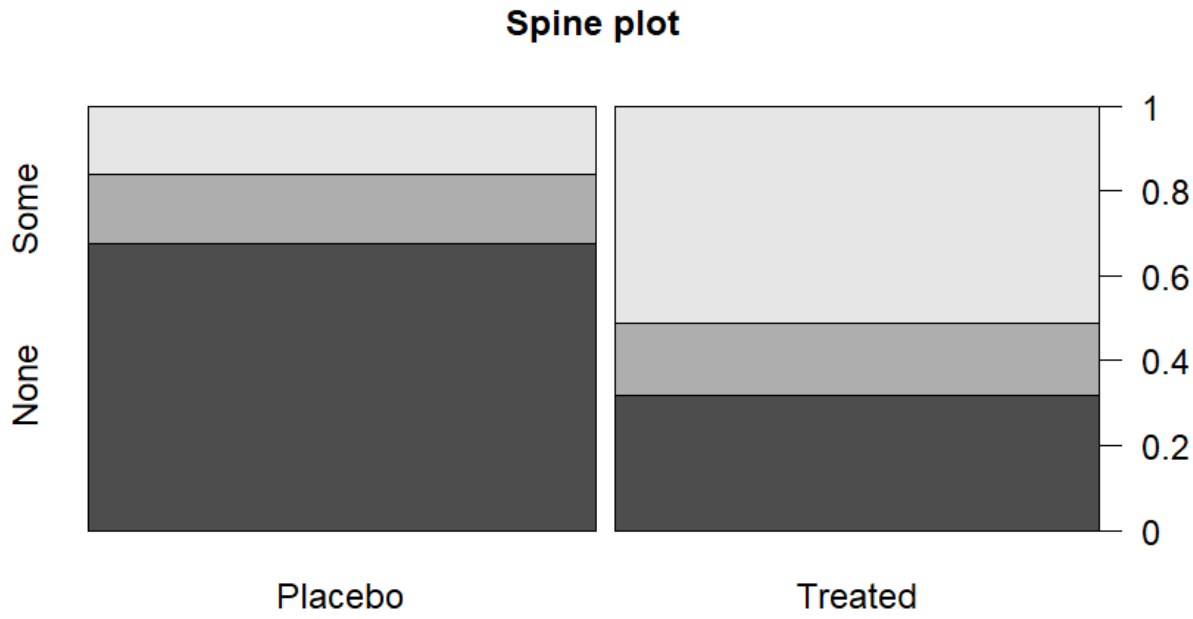
如果我们更关心列联表里的分配比例，而非具体频数，可以考虑脊线图。






```
1    spine(tab)
2    #tab 通常是一个列联表，可以通过table()函数从两个或更多的分类变
         量中创建
```

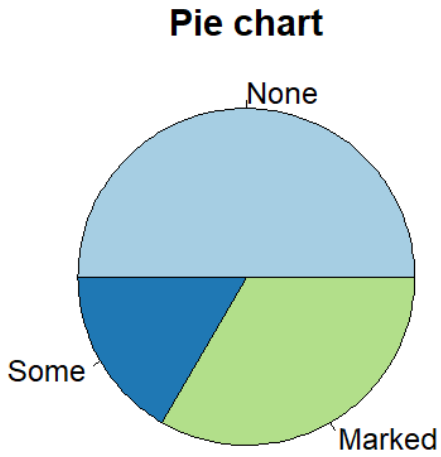
Spine plot




```
1  spine(table(treatment, improved))
2  #tab 通常是一个列联表, 可以通过table()函数从两个或更多的分类变
       量中创建
```

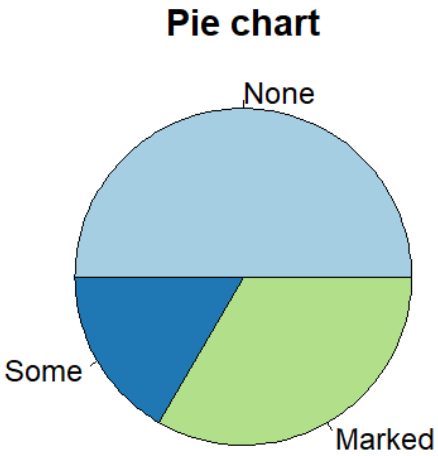
Pie charts 饼图

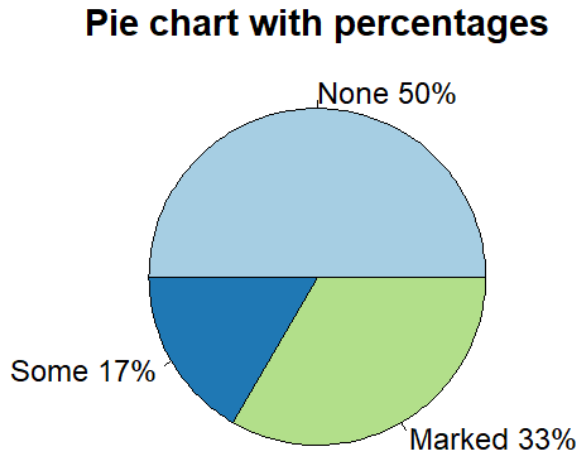
饼图是一种统计图表，用于显示一个数据集内各部分的比例关系。每个扇区（饼图中的“片”）的大小表示该部分在总体中的比例。饼图特别适合展示部分与整体之间的关系。



Pie charts 饼图

饼图是一种统计图表，用于显示一个数据集内各部分的比例关系。每个扇区（饼图中的“片”）的大小表示该部分在总体中的比例。饼图特别适合展示部分与整体之间的关系。



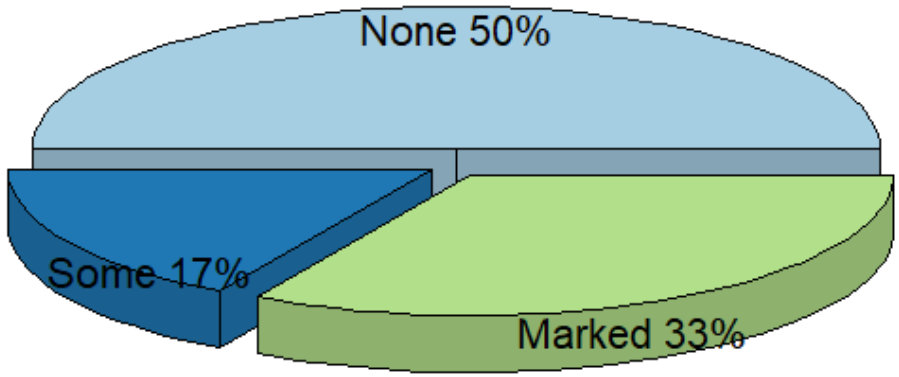


Pie

```
1       pie(x, labels = names(x), col = NULL, main = NULL)
```

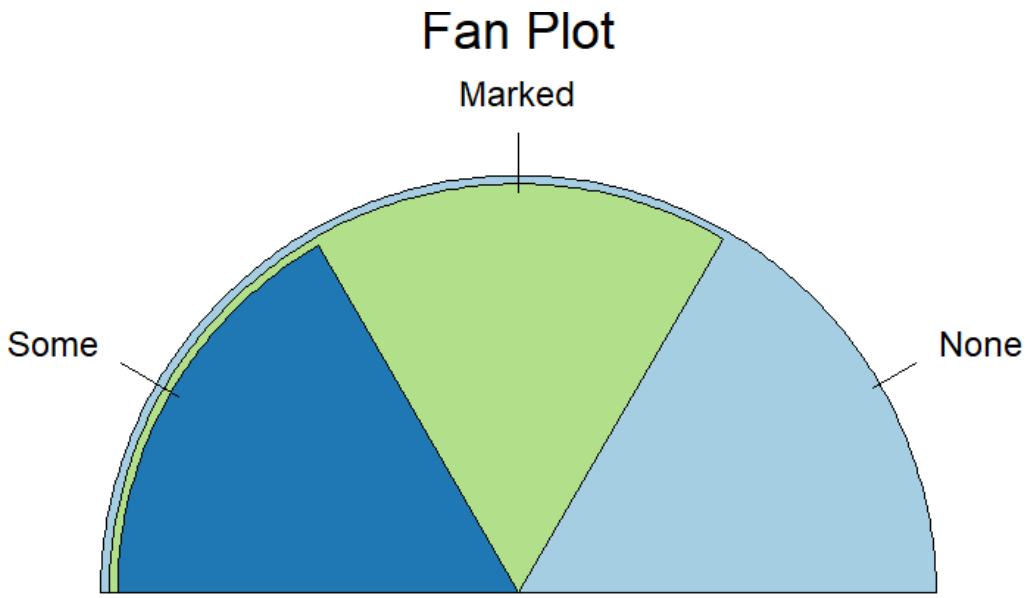
- x：包含要绘制的数据的频数
- labels：可选，与 x 中的数据项对应的标签向量
- col：可选，用于指定每个扇形的颜色
- main：可选，用于添加图表的主标题

3D pie




```
#pie3D()函数是由plotrix包提供的一个函数，用于在R中绘制三维饼图
pie3D(x, labels, explode, radius, main)
```

Fan plots 风扇图




```
1     fan.plot(x, labels, col, main)
```

注：风扇图在展示数据比例时提供了一种视觉上的变化，可以作为饼图的一个有趣的替代。然而，就像饼图一样，当类别数量较多时，风扇图也可能变得难以阅读。因此，在选择使用风扇图时，考虑数据的特点和展示的目的是很重要的。

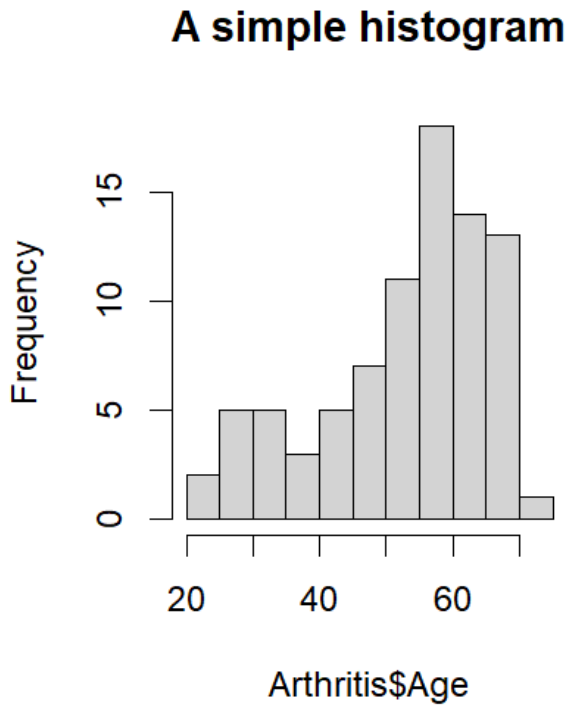
1 Review

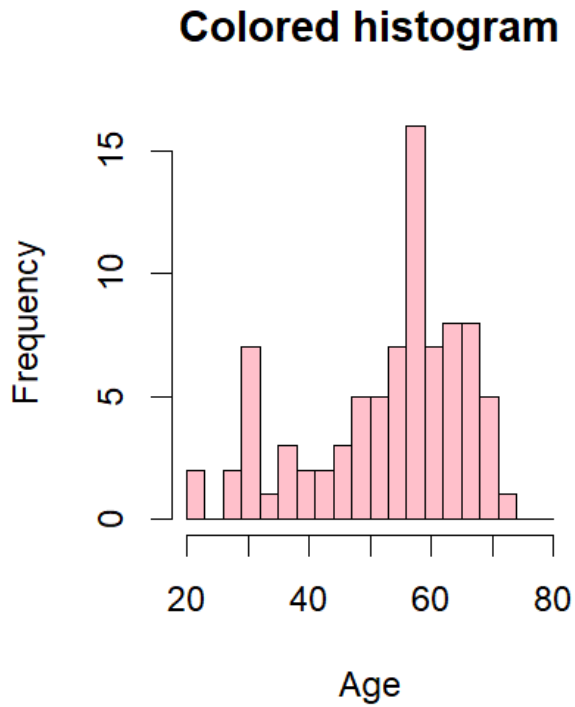
2 Basic graphs for categorical data

3 Basic graphs for numerical data

Histograms 直方图

- 直方图用来展示数据分布情况
- 通过将数据分组（每个组称为“桶”或“bin”）并计算每组中的数据点数量来工作
- 每个条形代表一个组，条形的高度表示该组中数据点的数量或密度



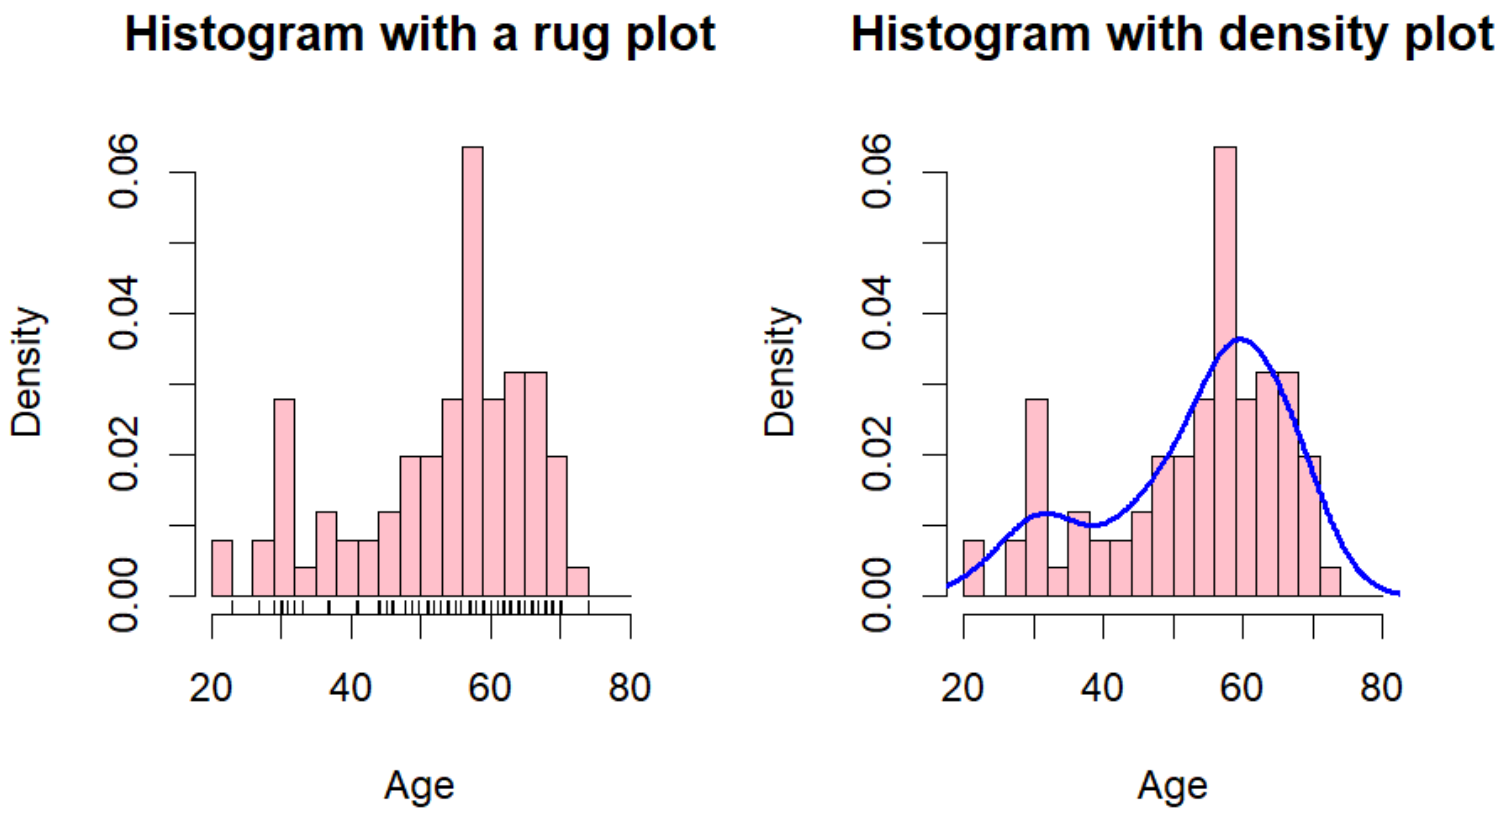


Histograms

```
1    hist(x)
2    hist(x, breaks, col, xlab, main)
```

- x：这是要绘制直方图的数值向量
- breaks：该参数控制箱体的数量。它可以是一个向量，给出直方图单元之间的断点；也可以是一个数字，给出直方图的单元数；或者是一个字符串，命名一个算法来计算单元数（例如，"Sturges"，"Scott"，"FD"），默认是"Sturges"

With density



With density

Rug 地毯图

- 地毯图是数据实际值的一维表示，可以添加到图形的底部或顶部
- 通过在图形的轴上直接标记出每个数据点的位置形成小标记（" 地毯" 标记），为数据分布提供直观视图。
- 在地毯图中，如果存在许多相同的值，点的重叠可能会成为问题。为了解决这个问题，可以使用 rug() 函数结合 jitter() 函数来添加地毯图

```
1       rug(jitter(x, amount = 0.01))
2       #jitter() 函数会给每个数据点添加一个小的随机值（在+-amount 的
            范围内的均匀随机变量），以避免点的重叠
```

With density

Kernel density plots 核密度估计

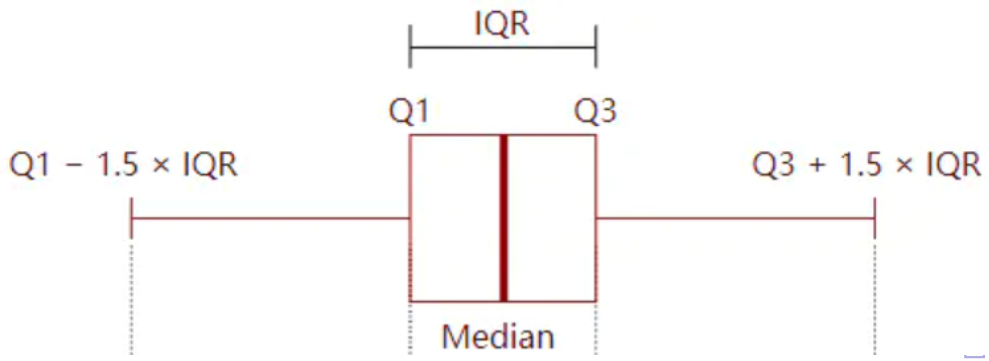
直方图展示了我们看到的频数；密度曲线展示了我们相信的分布

- 核密度估计（Kernel Density Estimate，KDE）是一种估计数据分布的平滑方法
- 可以生成一个连续的概率密度函数（非分段）
- 核密度估计能够提供一个更为平滑和连续的数据分布视图

```
#density() 函数基于数据自动计算一个平滑的密度曲线
#plot()将其画出
 plot(density(x))
```

Boxplots 箱线图

1. 中位数 (median)
   - 箱线图中间的线条表示数据的中位数，即将数据集分为数量相等的两部分的数值
2. 四分位数 (Quartiles)
   - 第一四分位数（Q1，25% 分位数）：数据中所有数值中排名前 25%
   - 第三四分位数（Q3，75% 分位数）：数据中所有数值中排名前 75%
   - 箱线图的 “箱子” 部分由 Q1 和 Q3 定义，这个箱体的高度（IQR，四分位间距）是数据分布中间 50% 的范围
3. 异常值 (Outliers)
   - 箱线图中可能会有一些用小圆点或星号标示的点，这些是异常值 (小于 Q1-1.5IQR 或大于 Q3+1.5IQR)
4. “胡须”(Whiskers)



Boxplots

箱线图的用途：

- 描述数据的分布：箱线图提供了关于数据位置和分散程度的快速概览
- 识别异常值：可以直观地识别数据中的潜在异常值
- 比较不同数据集：通过并排放置多个箱线图，比较不同数据集的中心趋势和变异程度

Boxplots

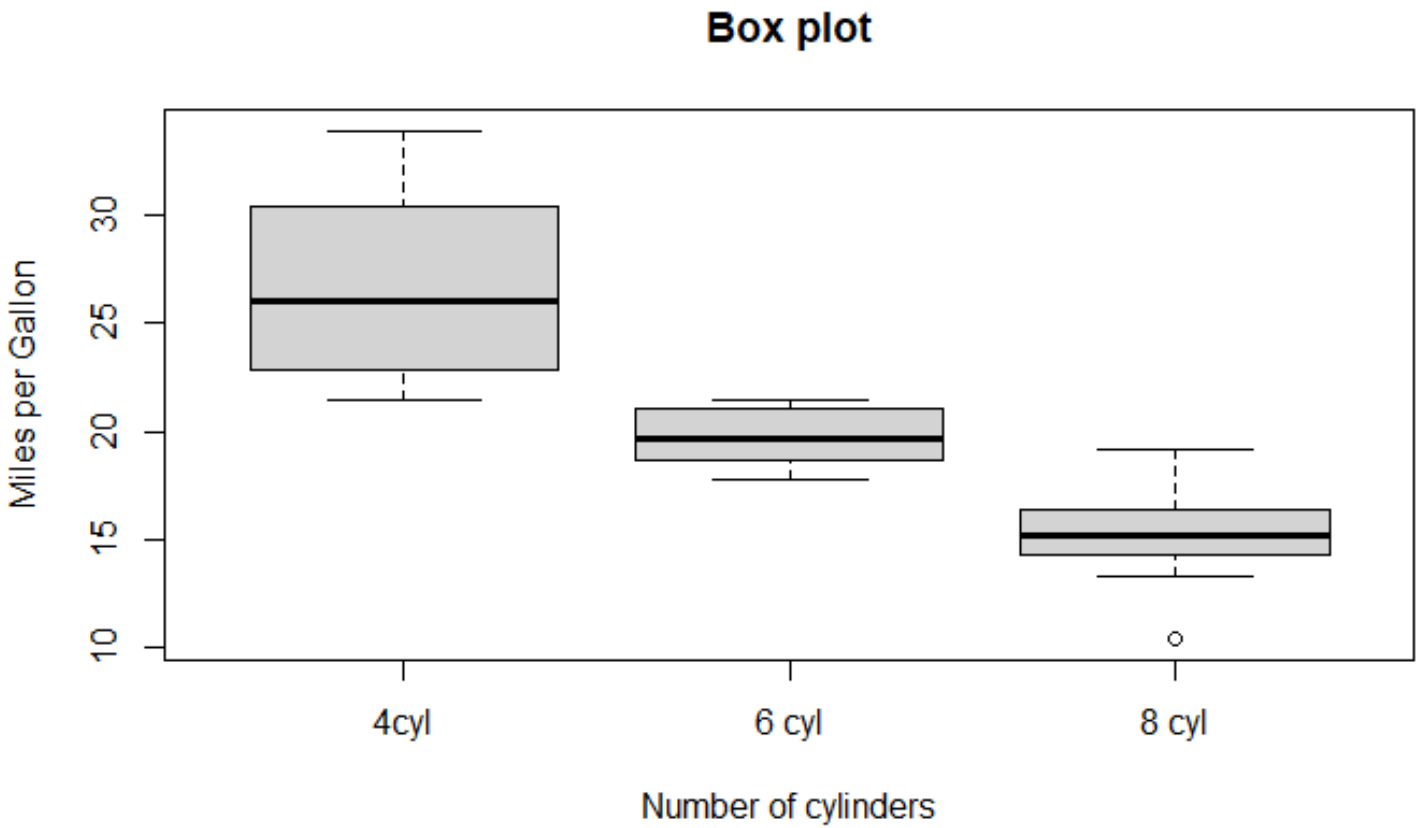
例子：mtcars

R 自带的 mtcars (32×11) 数据集，包含 1974 年美国汽车燃料效率（mpg）、气缸数（cyl）等数据。考察：

- 汽车的每加仑行驶英里数（miles per gallon, mpg）与汽车气缸数（cylinders, cyl）之间的关系

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6 cyl	160.0	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6 cyl	160.0	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4cyl	108.0	93	3.85	2.320	18.61	1	1	4	1

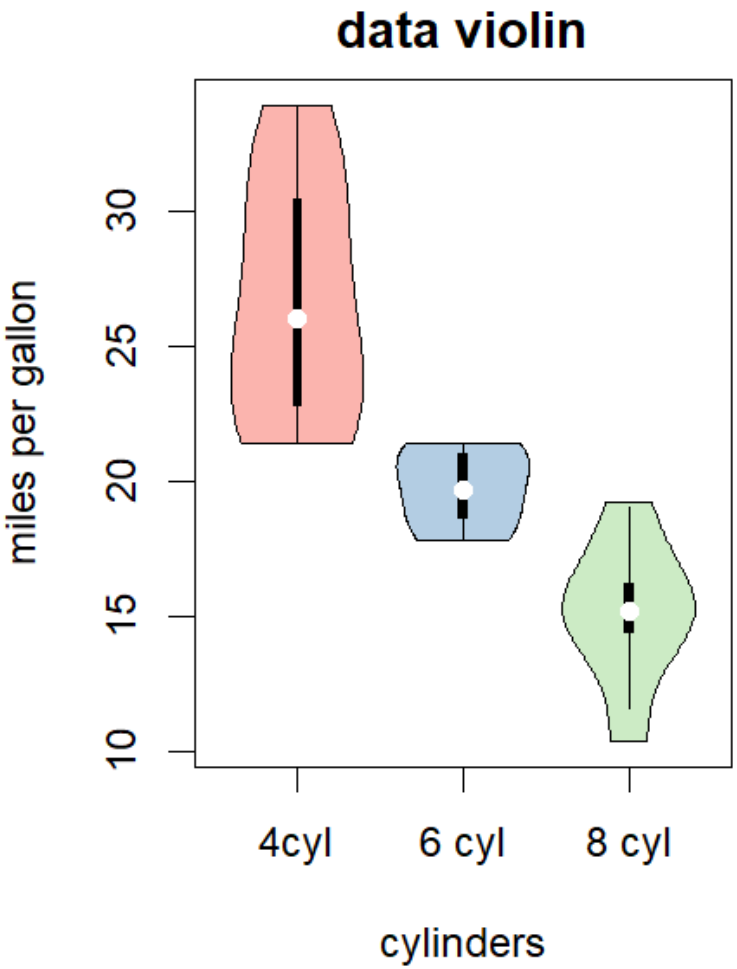
Boxplots

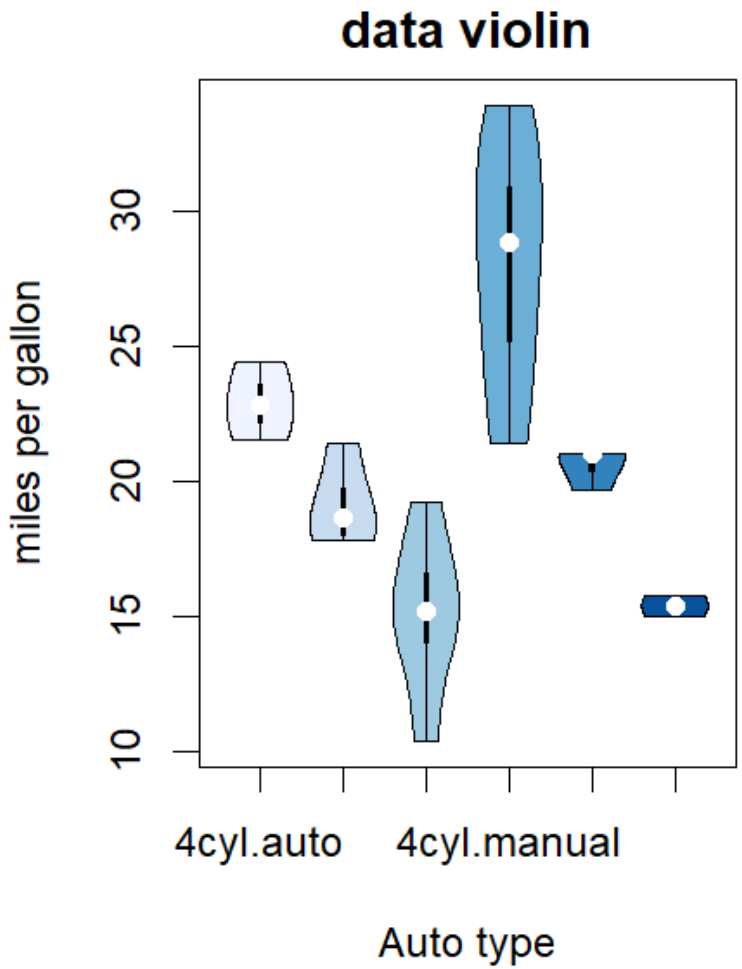



```
1    #以x为分组，以y为数值绘制箱线图
2    boxplot(y ~ x)
```

Violin plots 小提琴图

小提琴图结合了箱线图和核密度图的特点，适合展示数据的分布形状，同时也保留了显示中位数和四分位数的功能





Violin plots

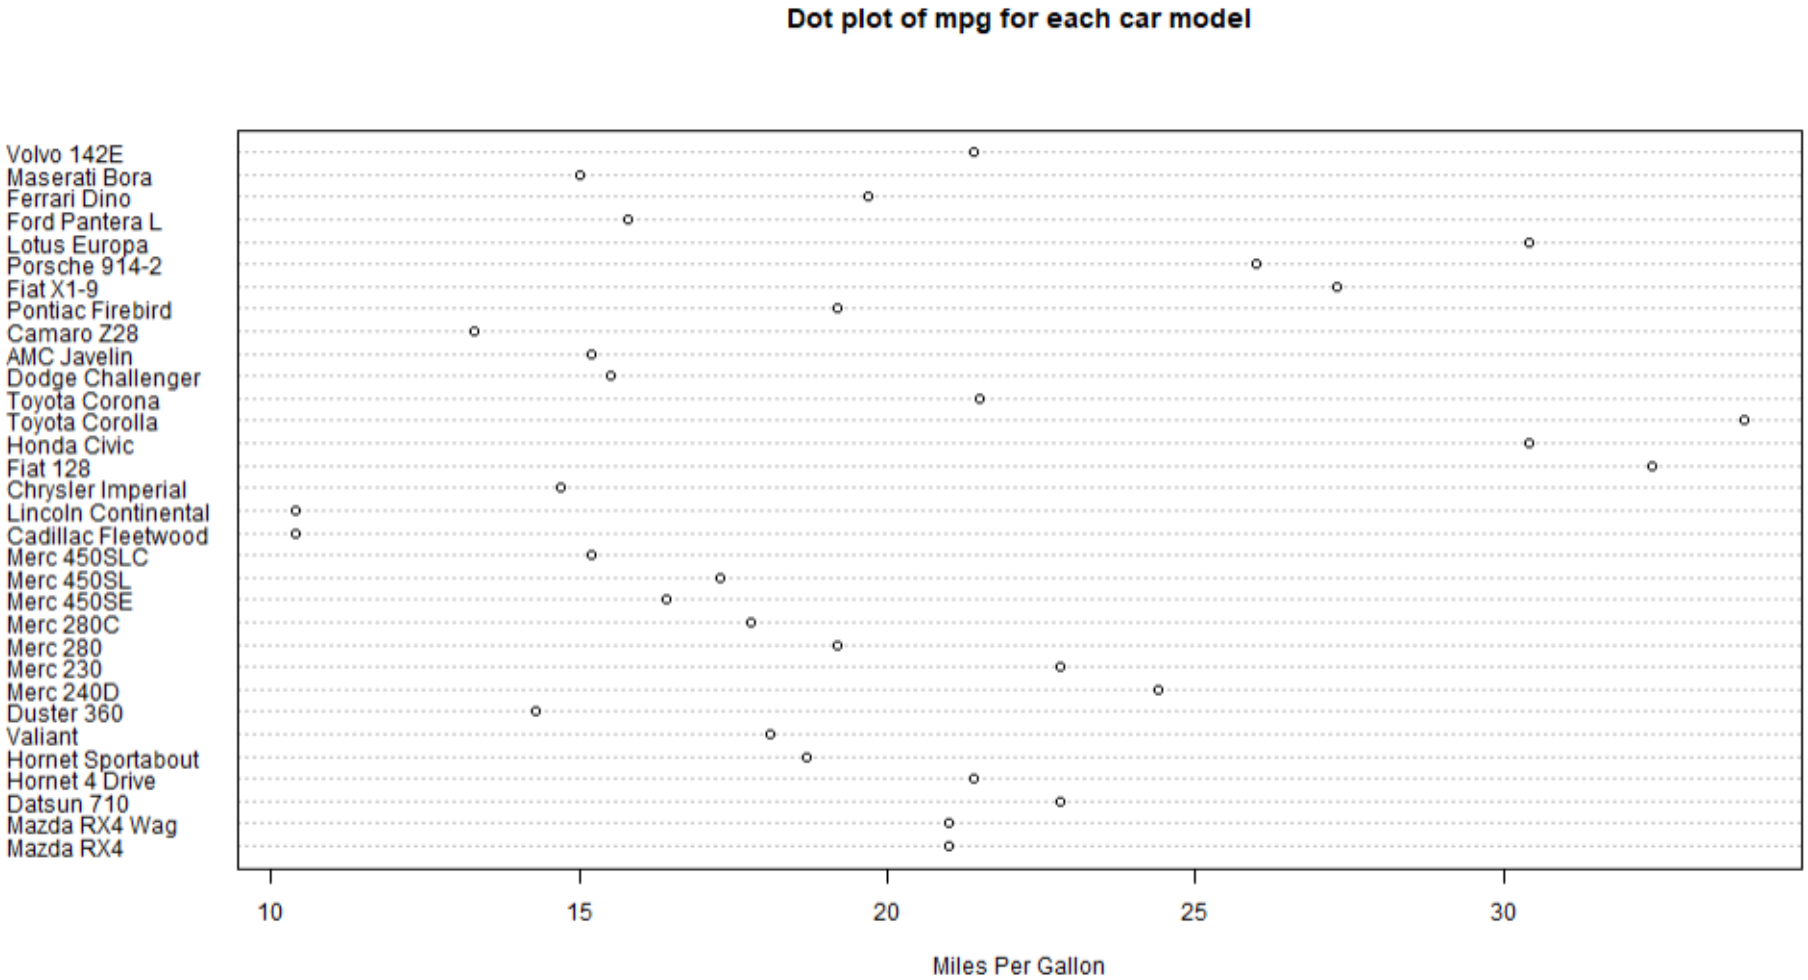
小提琴图的组成:

- 核密度估计：小提琴图的主体是数据的核密度估计，显示在中心轴的两侧，形状类似于小提琴
  - 这一部分图形显示了数据点在不同位置的集中程度，宽度越宽表示该位置的数据点越多
- 箱线图：通常在小提琴图内部绘制一个简化的箱线图，包括中位数、四分位数等
  - 有助于直观地看出数据的中心趋势和分散情况
- 异常值：有些小提琴图实现还会显示异常值，通常用点或小圆圈表示

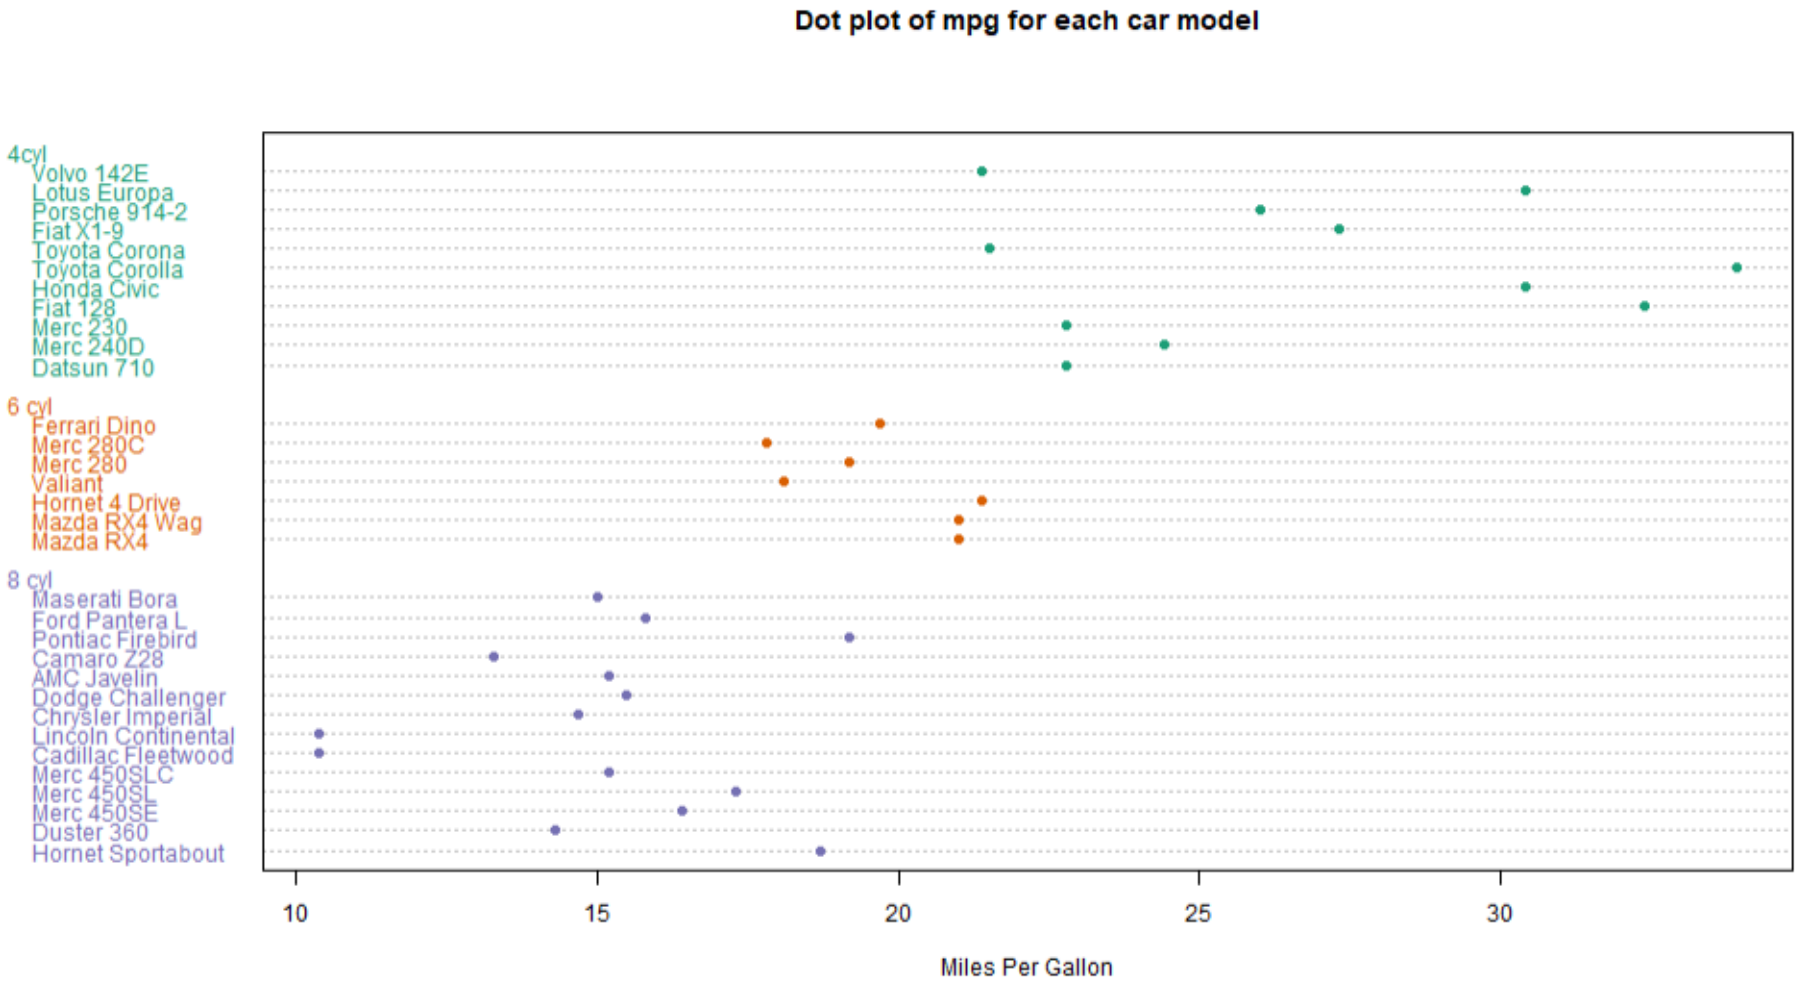
```
1          vioplot(y ~ x)
```

Dot plots 点图

点图通过水平或垂直的点来表示数值，通常用于显示不同分组或类别中的小型数据集的排列和比较。



Dot plots 点图

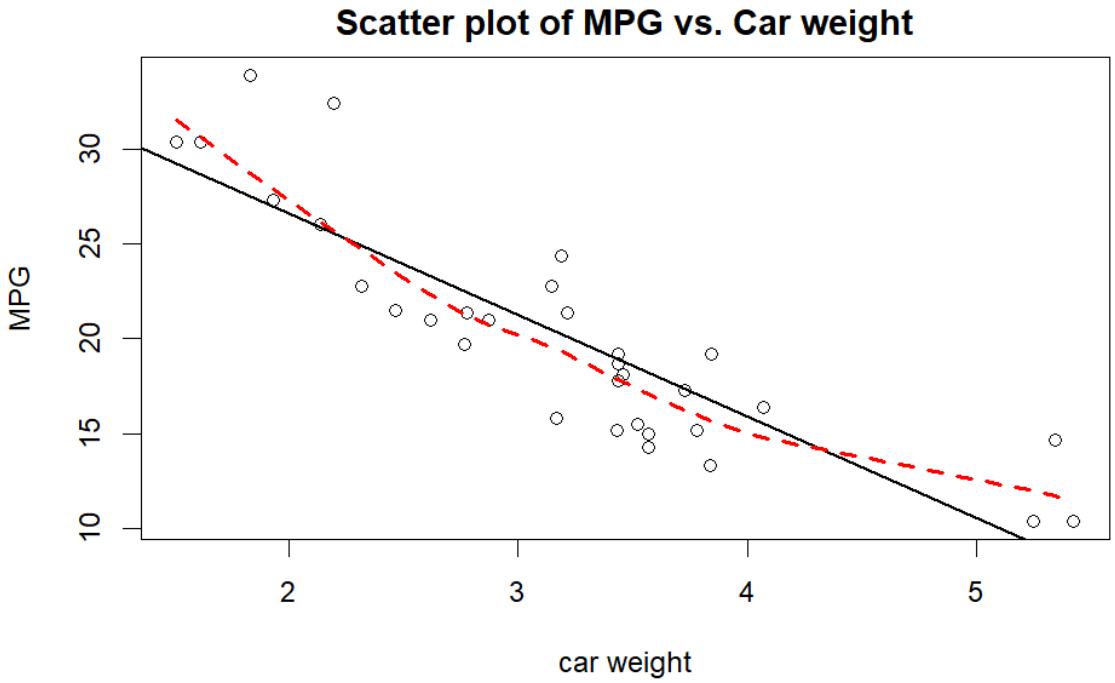

Dot plot of mpg for each car model
4cyl
Volvo 142E
Lotus Europa
Porsche 914-2
Fiat X1-9
Toyota Corona
Toyota Corolla
Honda Civic
Fiat 128
Merc 230
Merc 240D
Datsun 710
6 cyl
Ferrari Dino
Merc 280C
Merc 280
Valiant
Hornet 4 Drive
Mazda RX4 Wag
Mazda RX4
8 cyl
Maserati Bora
Ford Pantera L
Pontiac Firebird
Camaro Z28
AMC Javelin
Dodge Challenger
Chrysler Imperial
Lincoln Continental
Cadillac Fleetwood
Merc 450SLC
Merc 450SL
Merc 450SE
Duster 360
Hornet Sportabout
10
15
20
25
30
Miles Per Gallon

Dot plots

- 清晰的比较：点图通过在同一水平或垂直线上放置点来展示数值，使得比较不同项目的大小变得非常直观
- 简洁的表示：点图不使用条形的宽度或面积来表示数据，而是仅仅用点的位置来展示数值，从而减少了视觉上的混乱
- 适用于排序和排名：点图非常适合于显示排序或排名，因为点的位置可以精确到图上的特定位置，表明其相对大小

Scatter plots 散点图

- 两个数值型变量之间的关系
- 每个点代表一个样本



	mpg	wt
Mazda RX4	21.0	2.620
Mazda RX4 Wag	21.0	2.875
Datsun 710	22.8	2.320
Hornet 4 Drive	21.4	3.215
Hornet Sportabout	18.7	3.440
Valiant	18.1	3.460
Duster 360	14.3	3.570
Merc 240D	24.4	3.190
Merc 230	22.8	3.150
Merc 280	19.2	3.440
Merc 280C	17.8	3.440

```
1    plot(x, y)
```

Scatter plot

Linear line and Smoothed line

- abline(): add a linear line of best fit

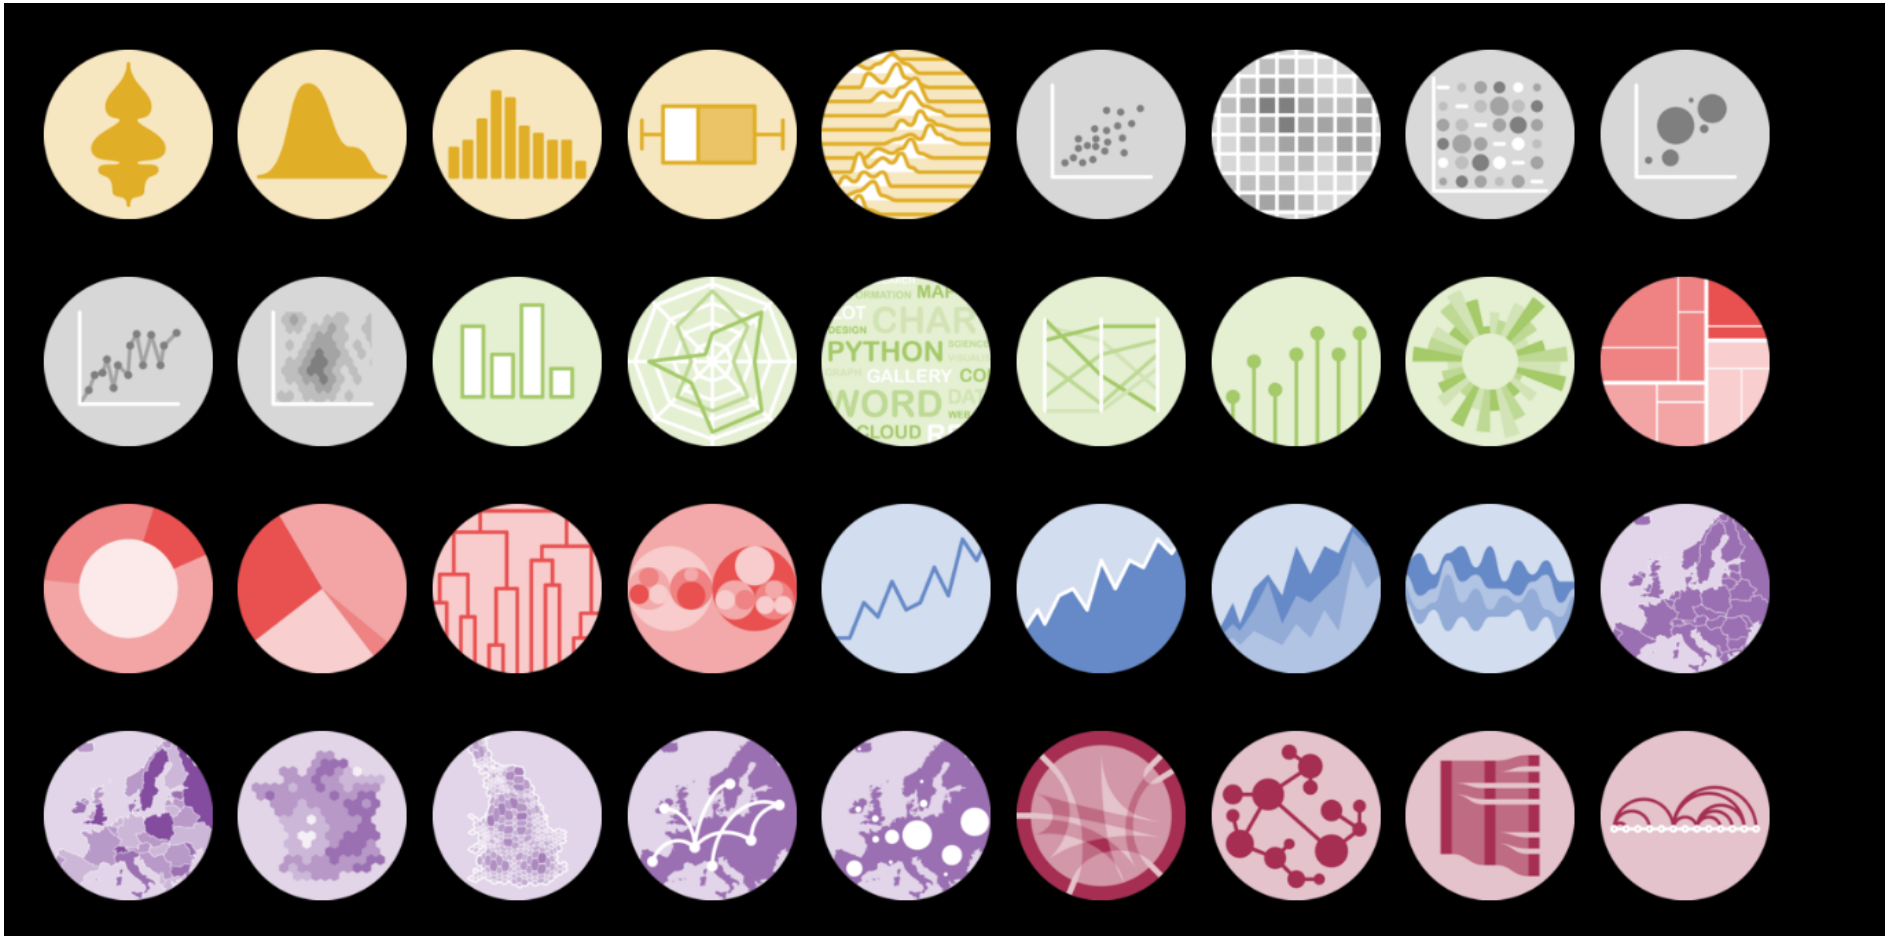
  Least Square Estimator
- lowess(): a smoothed line. It is a nonparametric fit line based on locally weighted polynomial regression.

  local; weight

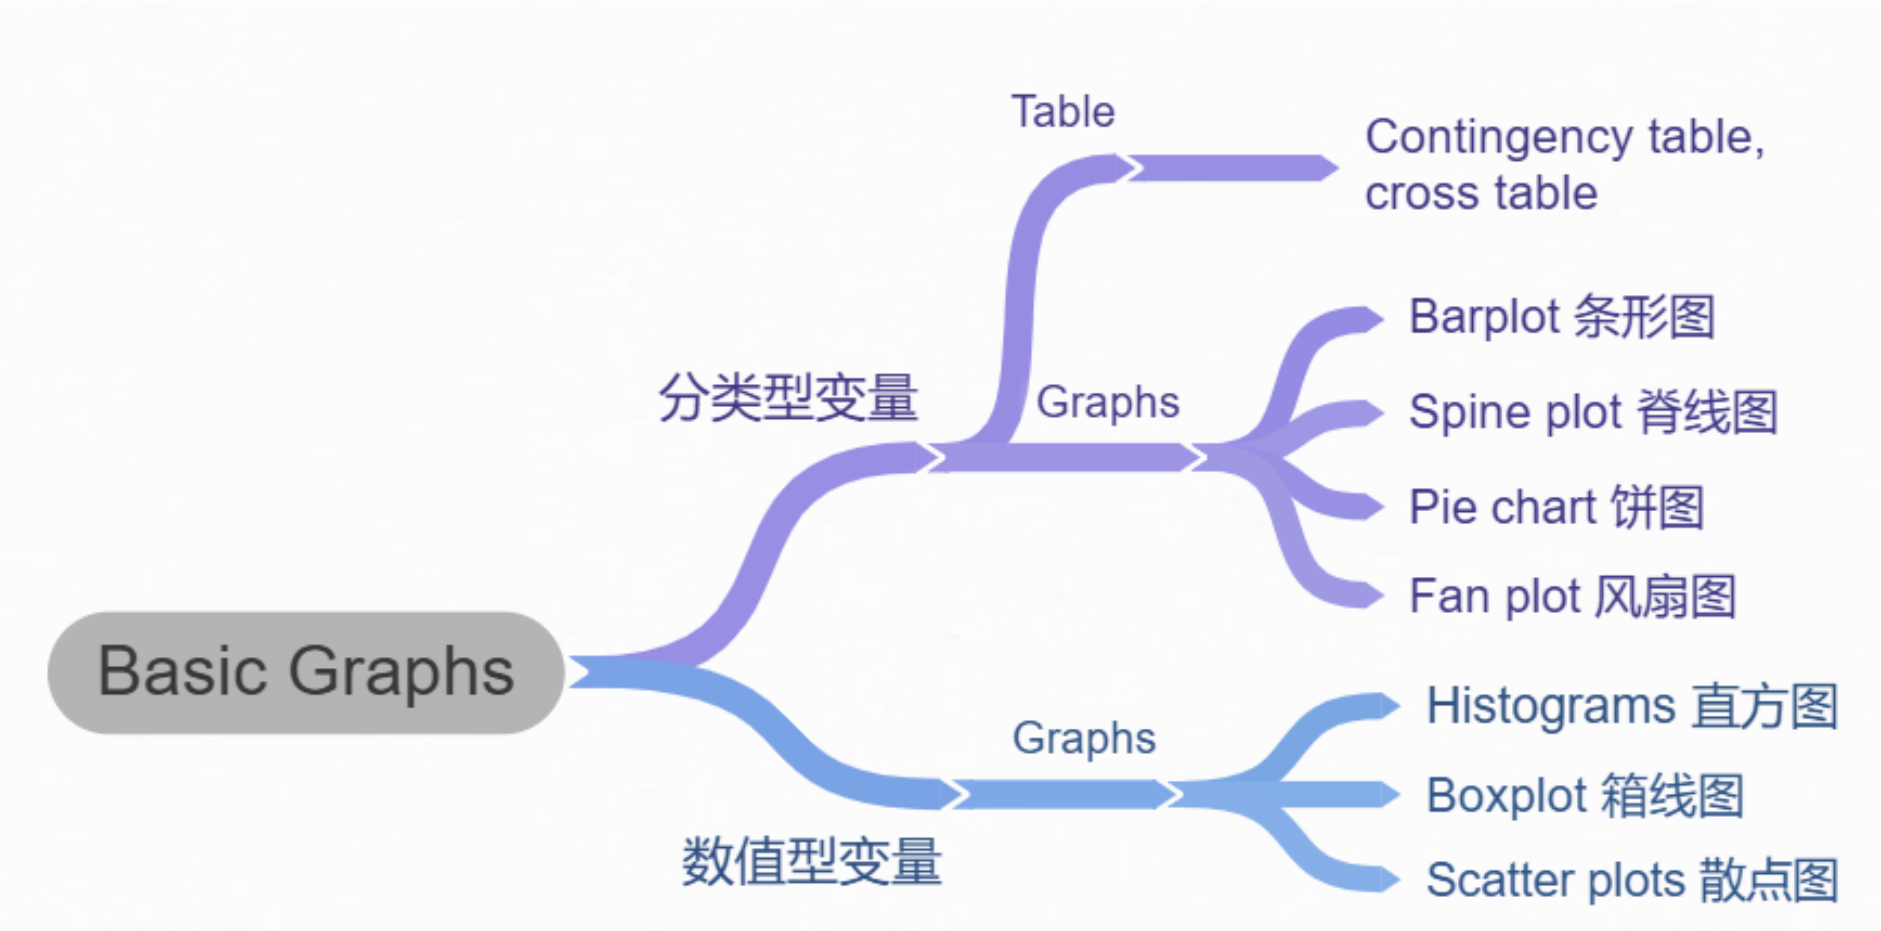
lowess

- "local": the size of neighbourhood, controls the smoothness of the curve. In general, the smaller the neighbourhood, the more that lowess curve follows individual data points. To obtain a smoother lowess curve, increase the neighbourhood size.
- "weight": normally 1 or 2.

The R graph gallery



Summary


Basic Graphs
分类型变量
Table
Contingency table,
cross table
Graphs
Barplot 条形图
Spine plot 脊线图
Pie chart 饼图
Fan plot 风扇图
数值型变量
Graphs
Histograms 直方图
Boxplot 箱线图
Scatter plots 散点图

Exercise

探索 iris 数据集中变量的分布和不同鸢尾花种类的特征差异

- 为 iris 数据集中的 Sepal.Length 变量创建一个直方图 histogram，以查看萼片长度的分布
- 使用 table 函数对 Species 变量进行计数，然后为不同种类的鸢尾花创建一个条形图 barplot
- 为每种鸢尾花的 Petal.Width 创建箱线图 boxplot，以比较不同种类鸢尾花的花瓣宽度分布
- 为 Petal.Length 按 Species 分组创建提琴图 vioplot，比较不同种类鸢尾花的花瓣长度分布
- 创建一个散点图，将 Sepal.Length 作为 x 轴，Sepal.Width 作为 y 轴，用不同颜色表示不同的 Species