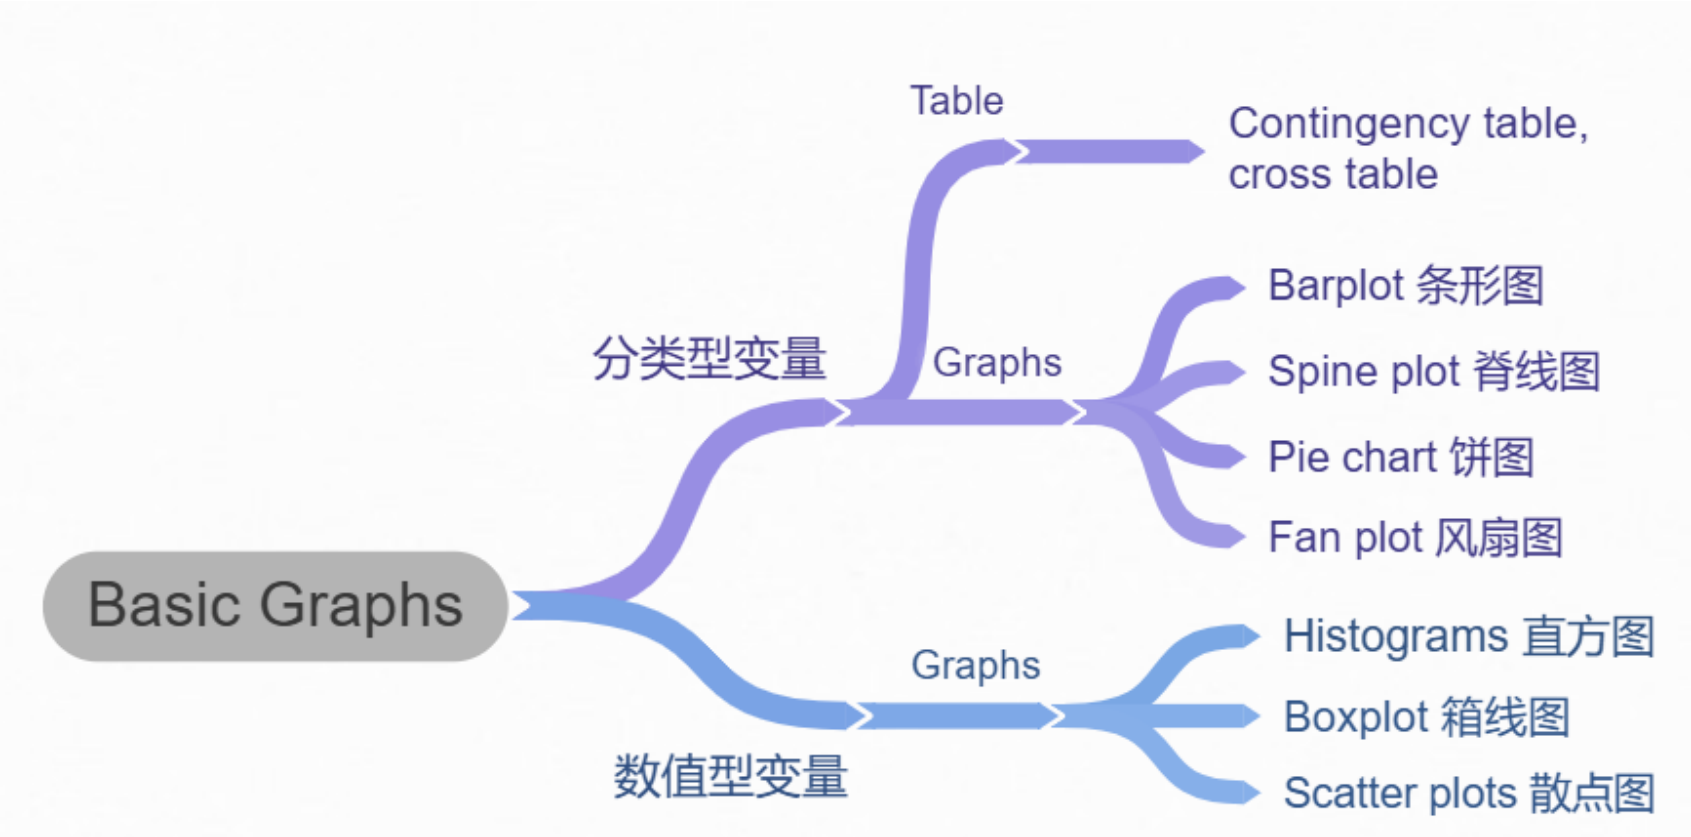
Basic Statistics

Jiayun Jin

Review


Basic Graphs
分类型变量
Table
Contingency table,
cross table
Graphs
Barplot 条形图
Spine plot 脊线图
Pie chart 饼图
Fan plot 风扇图
数值型变量
Graphs
Histograms 直方图
Boxplot 箱线图
Scatter plots 散点图

数据的概括性度量

描述统计

1. 集中趋势的度量
2. 离散程度的度量
3. 分布形状的度量

集中趋势的度量

集中趋势：一组数据向某一中心值靠拢的程度

平均数

- 简单平均数

$$\bar{x} = \frac{x_1 + x_2 + \ldots + x_n}{n} = \frac{\sum_{i=1}^{n} x_i}{n}$$

- 加权平均数

$$\bar{x} = \frac{\sum_{i=1}^{k} w_i x_i}{\sum w_i}$$

每个样本都有相应的权重，这些权重反映了每个样本在总体中的相对重要性

加权平均数

使用场景

- 不同重要性的样本：确保样本对平均数的贡献与其重要性成正比
- 不均匀的样本大小：平衡不同大小的子集对总平均值的影响
- 时间序列数据：因近期数据可能比陈旧数据更有参考价值，通常给近期数据更高的权重

集中趋势的度量

分位数：一组数据从小到大排序，排在某个位置上的数值就是相应的分位数，包括中位数、四分位数等。

中位数 M_e

- 一组数据排序后处在中间位置上的数值
- 不受极端值影响，在研究收入分配时很有用
- 计算公式：

$$M_e = \begin{cases} x_{(\frac{n+1}{2})} & n\text{为奇数} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n+1}{2})}) & n\text{为偶数} \end{cases}$$

集中趋势的度量

四分位数

- 一组数据排序后处于 25% 和 75% 位置上的数值
- 计算公式：

$$Q_1\text{位置} = \frac{n+1}{4}; \qquad Q_3\text{位置} = \frac{3(n+1)}{4}$$

- 例子 3， 5, 9, 13, 24, 43, 57, 68, 77, 87

$$Q_1\text{位置} = \frac{11}{4} = 2.75$$

$$Q_1 = 5 + 0.75 \times (9 - 5) = 8$$

$$Q_3\text{位置} = \frac{11 \times 3}{4} = 8.25$$

$$Q_3 = 68 + 0.25 \times (77 - 68) = 70.25$$

集中趋势的度量

众数 M_o

- 数据集中趋势的度量
- 出现次数最多的数值

特点：

- 可以不存在或有多个
- 对数据中的异常值不敏感，因此是描述类别数据或有明显峰值的数据的好方法

集中趋势的度量

几何平均数

$$G = \sqrt[n]{x_1 \times x_2 \times \ldots \times x_n} = \sqrt[n]{\prod_{i=1}^{n} x_i}$$

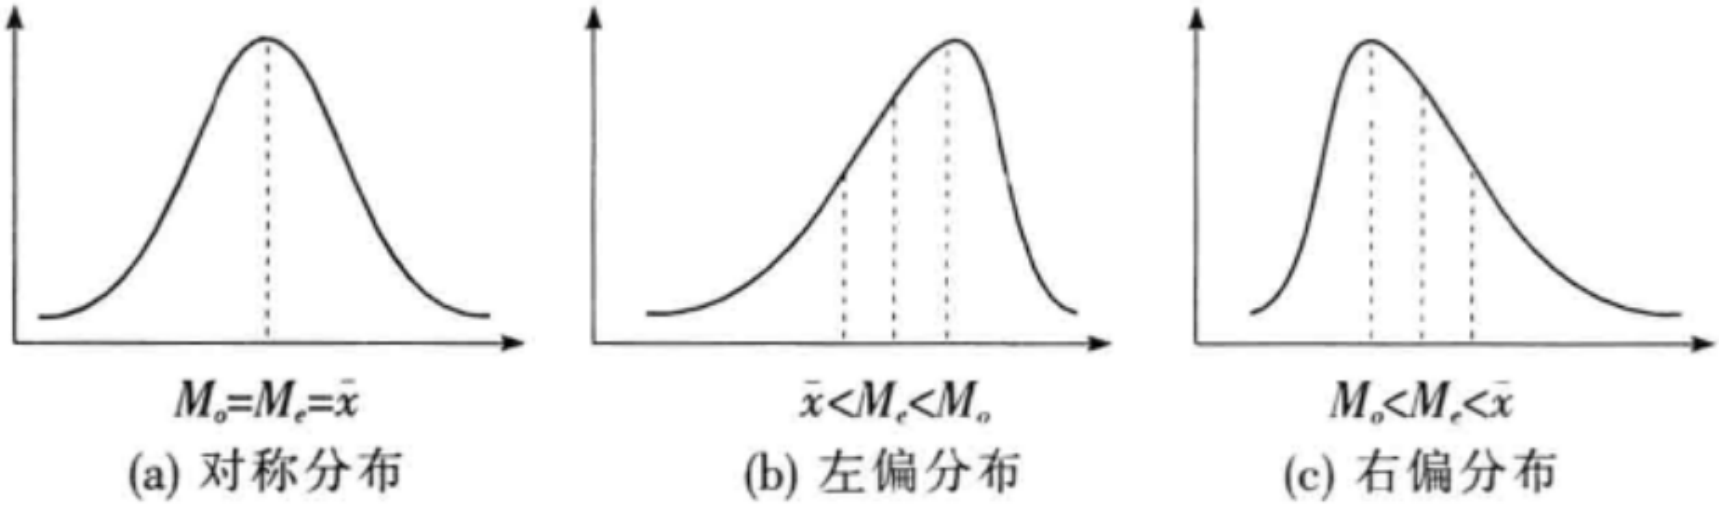
- 比率和增长率
- 非增长率情景：
  - 合成指标

    在创建涉及多个度量标准的合成指数时，如果这些度量标准的单位不统一或涉及到不同的比例，几何平均数可以平衡它们的贡献，从而避免因单个指标的极端值而导致整体指标失真
  - 调和不同尺度的数据

    在科学研究和工程应用中，当需要整合不同尺度或量级的数据时，几何平均数提供了一种减少极端影响并保持数据比例的方法
  - 风险评估

众数、中位数和平均数的比较

- 均值受极端值影响较大，众数 M_o 是一组数据分布的峰值
- 当数据为偏态分布，特别是偏斜程度较大时，可以考虑选择中位数或众数



离散程度的度量

全距 (Range)

$$R = max(x) - min(x)$$

只利用了数据两端的信息，容易受极端值的影响

四分位距 (inter-quartile range)

$$IQR = Q_3 - Q_1$$

IQR 反映了中间 50% 数据的离散程度：

- 其数值越小，中间的数据越集中
- 其数值越大，中间的数据越分散
- 四分位距不受极值的影响，且对异常值具有较好的抗性

离散程度的度量

方差和标准差

考虑每个数据 x_i 与其平均数 $\bar{x}$ 之间的差异：

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

- 标准差具有量纲，与原始数据的计量单位相同，其实际意义要比方差清楚；采用不同计量单位计量的数据，标准差的值也就不同
- 数值大小受原始数据取值大小的影响：数据的观测值越大，标准差的值通常越大
- 受异常值的影响，它基于所有数据点与平均值的偏差

离散程度的度量

例子：非洲象和花园蚂蚁

- 大象的体重（千克）：[5000, 5400, 5200, 5100, 5300]

$$S_{\text{象}} = 158.1139$$

- 蚂蚁的体重（毫克）：[3, 4, 2, 3, 5]

$$S_{\text{蚁}} = 1.14$$

- 在比较不同数据集的离散程度时，应考虑数据的尺度和单位
- 标准差作为测量数据分布散度的工具，其有效性和解释力依赖于对数据的理解和数据本身的性质
- 在实际应用中，标准差帮助我们理解数据的变异性，而变异性的相对大小更适合用标准化的度量（如变异系数）来评价，特别是在单位和尺度差异显著时

离散程度的度量

离散系数 coefficient of variation

- 一组数据的标准差与平均数之比
- 消除了数据取值大小和计量单位对标准差的影响

$$CV = \frac{s}{\bar{x}}$$

主要用于比较不同样本数据的离散程度

- 离散系数大说明数据的相对离散程度也大，离散系数小说明相对离散程度也小

$$CV_{象} = 0.03; CV_{蚁} = 0.34$$

离散程度的度量

标准分数

基于平均数和标准差：

$$z_i = \frac{x_i - \bar{x}}{s}$$

用来描述某个数据与平均数相比相差多少个标准差

- 比较：跨尺度（如考试分数和身高）比较数据
- 识别异常值:
  - 切比雪夫不等式：至少有 $1 - 1/k^2$ 的数据落在 $\pm k$ 个标准差之内：75% 的数据落在平均数 ± 2 个标准差范围内；94% 的数据落在平均数 ± 4 个标准差范围内
- 标准化

离散程度的度量

标准分数：非洲象和花园蚂蚁

- 大象的体重（千克）：[5000, 5400, 5200, 5100, 5300]

  标准得分：-1.2649 1.2649 0.0000 -0.6324 0.6324

- 蚂蚁的体重（毫克）：[3, 4, 2, 3, 5]

  标准得分：-0.3508 0.5262 -1.2278 -0.3508232 1.4032

分布形状的度量

偏度 skewness

$$SK = \frac{n}{(n-1)(n-2)} \sum (\frac{x_i - \bar{x}}{s})^3$$

- 偏度系数为 0 时，数据成对称分布，如正态分布
- 正偏度：数据的右尾（高值端）较长，有一些极高的值延伸到右侧
- 负偏度；数据的左尾（低值端）较长，有一些极小的值延伸到左侧

分布形状的度量

偏度

- 数据转换
  - 对数转换：适用于正偏数据，可以帮助压缩大数值，拉伸小数值，减少偏度
  - 平方根转换：同样适用于正偏数据，可以处理零值。通常不如对数转换那么强烈，适合于偏度较小的情况
- 非参数方法
- 决策
  - 风险管理及产品质量控制

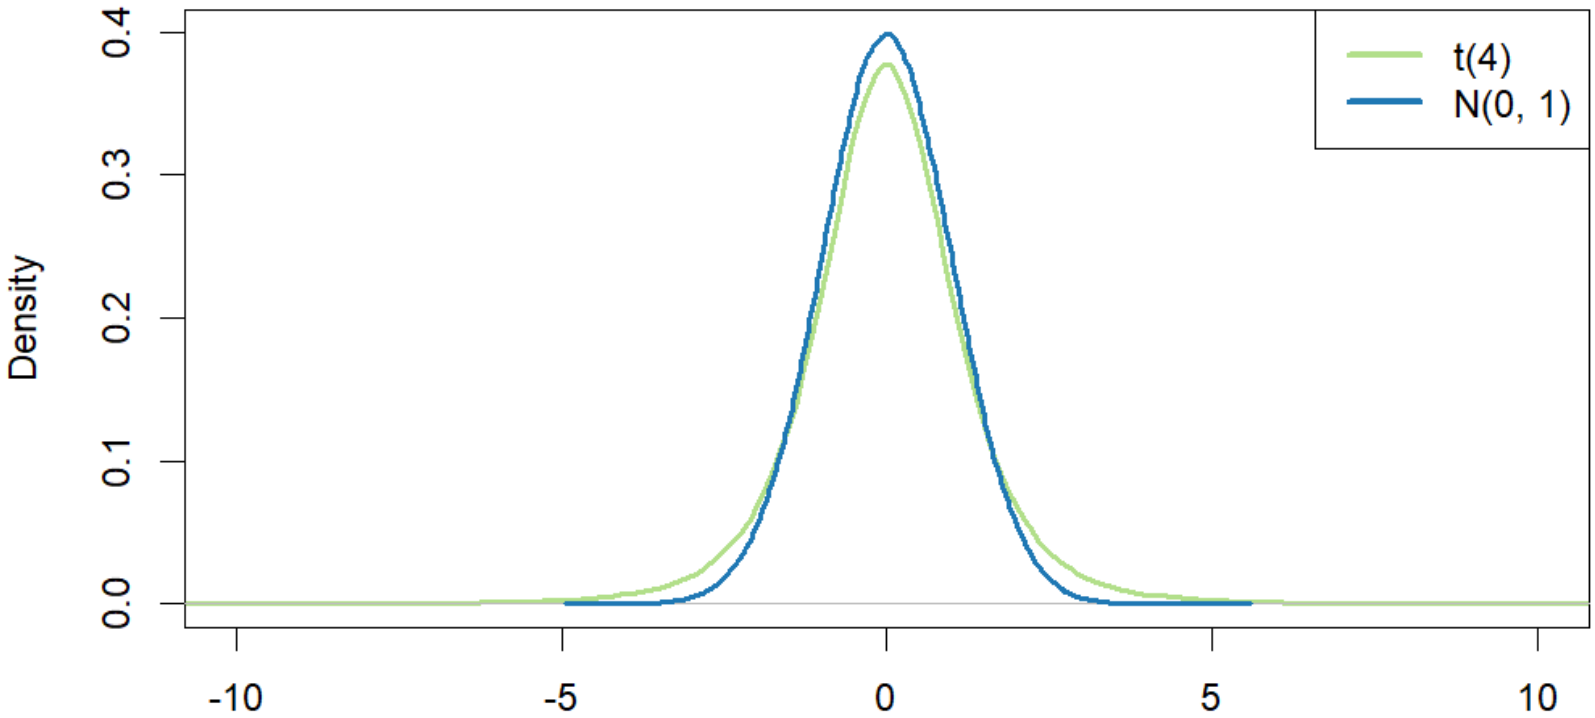
分布形状的度量

(超值) 峰度系数 (excess) kurtosis

- 一组数据分布峰值高低的统计量

$$K = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum \left(\frac{x_i - \bar{x}}{s}\right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}$$

- 峰度通常与正态分布相较而言，正态分布峰度系数为 0
- $K > 0$ 时为尖峰分布，数据分布比正态分布高，数据相对集中，具有更厚的尾部。
- $K < 0$ 时为扁平分布，数据分布比正态分布低，数据相对分散，尾部较薄



- 在中心附近，相对于正态分布，t 分布有更低的概率密度
- t 分布的尾部更厚，表明它在尾部的概率密度大于正态分布

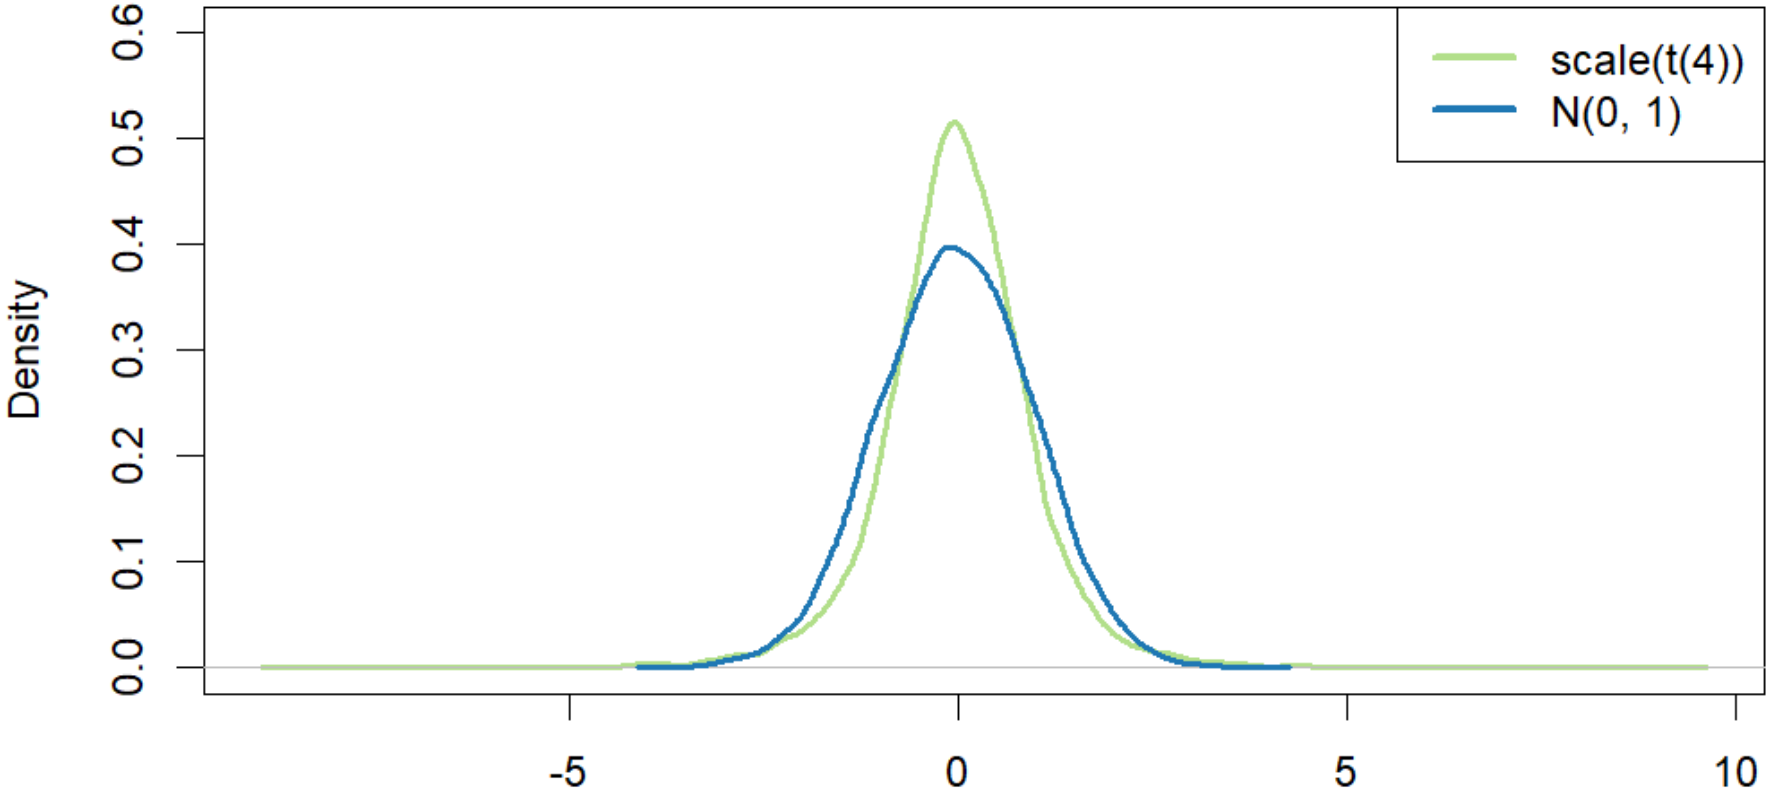
分布形状的度量

峰度

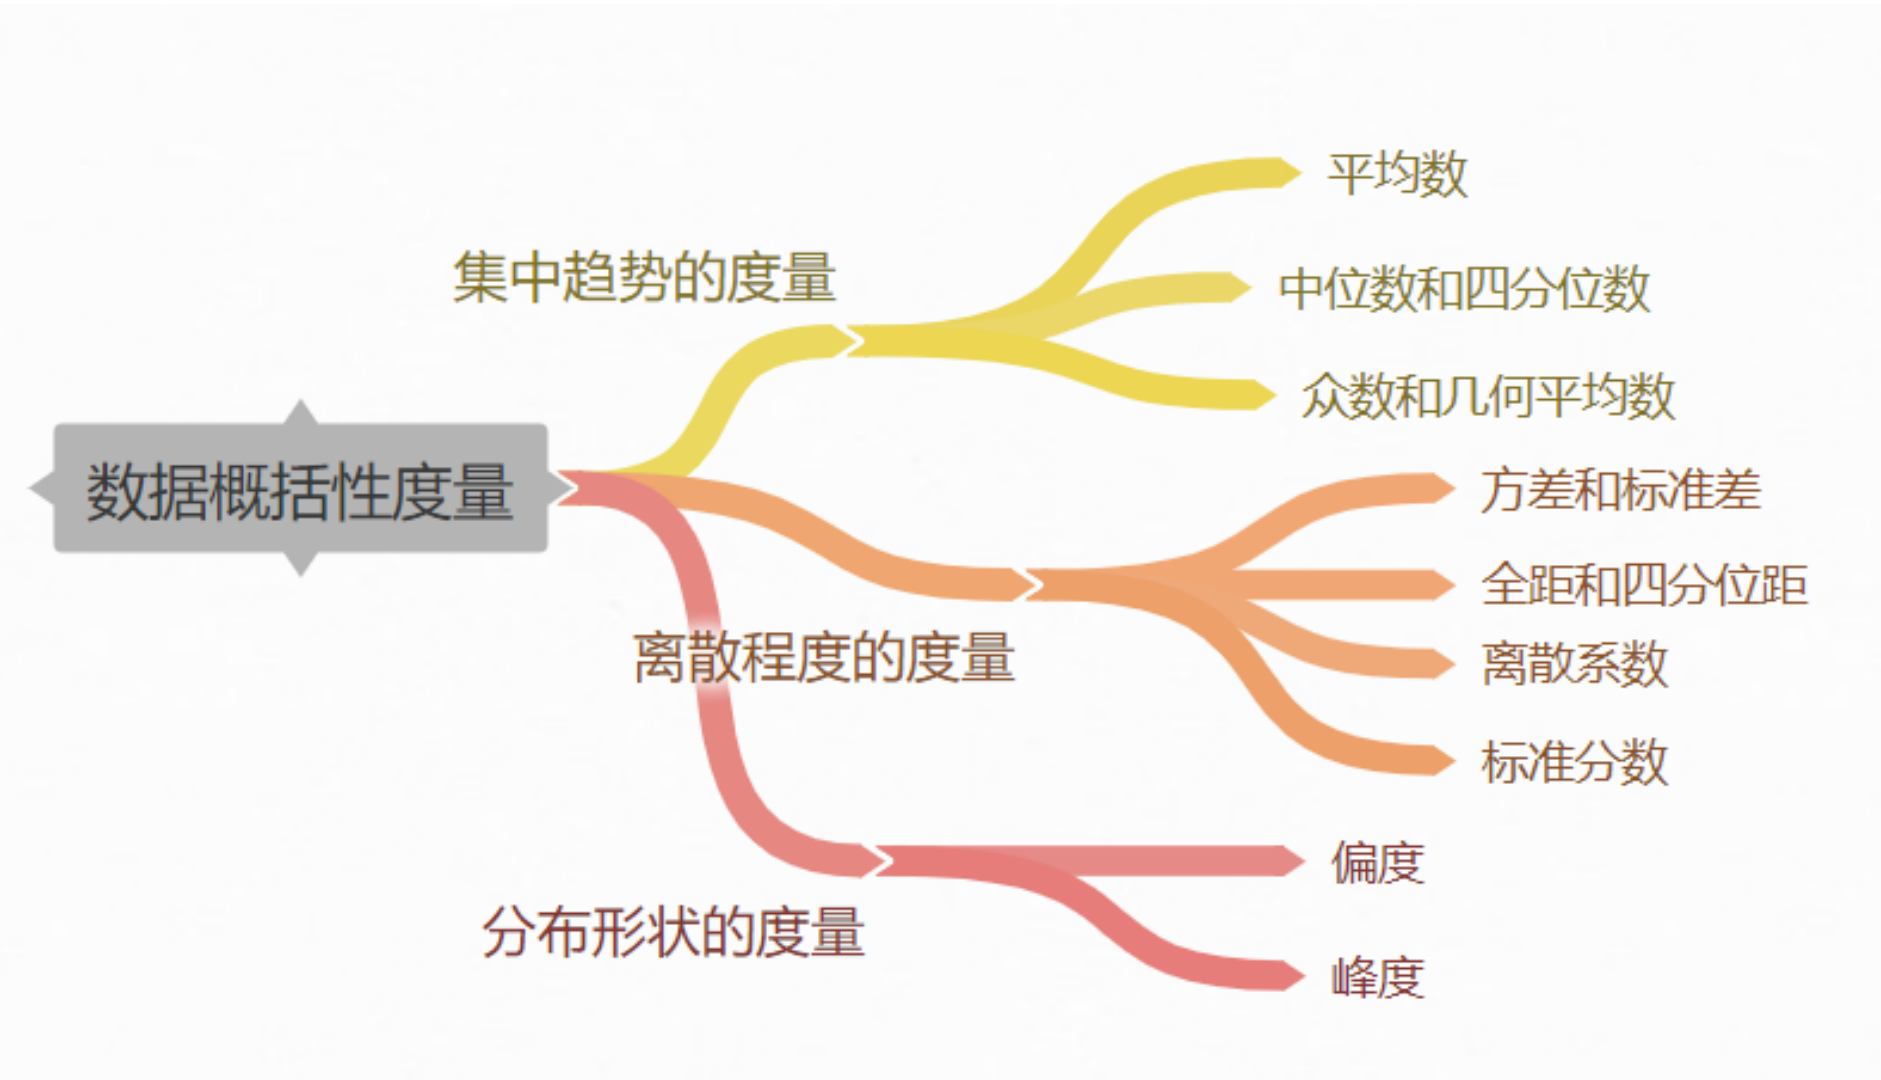
尽管 t 分布在中心峰值附近看起来不如正态分布尖锐，但其实它具有更高的峰度

- 峰度不仅仅考虑中心峰的高度，还考虑尾部的厚度 (tail thickness)
- 由于 t 分布的尾部比正态分布更重，它在分布的尾端有更多的极端值，这就导致了更高的峰度值
- 高峰度的分布意味着极端值（非常大或非常小的值）出现的可能性比正态分布要大

峰度比直观含义的 ‘‘峰’’ 形状更为复杂，涉及到分布的中心峰和尾部的整体形状


Density
0.0
0.1
0.2
0.3
0.4
0.5
0.6
-5
0
5
10
scale(t(4))
N(0, 1)

数据的概括性度量度量回顾



作业

小组为单位，对一份数据进行简单描述统计分析，要求：

1. 自选（或自创）数据，变量至少包括一个分类型变量，一个数值型变量，并用 R 读取导入。
2. 根据数据特征选择 2 到 3 种图表进行展示，尽量尝试使用 ggplot 包画至少一个图
3. 对数据进行集中趋势、离散程度以及分布形状的描述
4. 作业形式为一份 10 分钟左右 ppt。汇报内容包括数据基本情况、R 代码解释、图表结果及相应简单描述。

Deadline: 5.8 (周四) 12pm